

FACULDADE ANGLO-AMERICANO DE FOZ DO IGUAÇU

THIAGO MEDEIROS DE SOUZA

**MINERAÇÃO DE DADOS APLICADO À REDE SOCIAL *TWITTER*
UTILIZANDO A LINGUAGEM DE PROGRAMAÇÃO PYTHON**

FOZ DO IGUAÇU

2016

THIAGO MEDEIROS DE SOUZA

**MINERAÇÃO DE DADOS APLICADO À REDE SOCIAL *TWITTER*
UTILIZANDO A LINGUAGEM DE PROGRAMAÇÃO PYTHON**

Trabalho de conclusão de curso apresentado
como requisito obrigatório para obtenção do tí-
tulo de Bacharel em Ciência da Computação da
Faculdade Anglo-Americano de Foz do Iguaçu.

Orientador: Prof. Msc. Valmei Abreu Júnior

Coorientador: Prof. Esp. João Paulo de Lima
Barbosa

FOZ DO IGUAÇU

2016

TERMO DE APROVAÇÃO

THIAGO MEDEIROS DE SOUZA

MINERAÇÃO DE DADOS APLICADO À REDE SOCIAL *TWITTER* UTILIZANDO A LINGUAGEM DE PROGRAMAÇÃO PYTHON

Trabalho de conclusão de curso apresentado como requisito obrigatório para obtenção do título de Bacharel em Ciência da Computação da Faculdade Anglo-Americano de Foz do Iguaçu, pela seguinte banca examinadora:

Prof. Msc. Valmei Abreu Júnior
Faculdade Anglo-Americano
(Orientador)

Prof. Banca 2
Faculdade Anglo-Americano

Prof. Banca 3
Faculdade Anglo-Americano

Foz do Iguaçu, 26 de abril de 2016

*Dedico este trabalho a meus pais,
Valmir M. de Souza e Maria Emilia M. de Souza
que, com muito amor, me ensinaram os valores da vida.*

AGRADECIMENTOS

Primeiramente agradeço a Deus por sua graça e salvação.

À minha família, por terem me proporcionado oportunidades únicas e as melhores condições de estudo.

À Elyn Hsu, por me mostrar o caminho da disciplina e amor que me incentivaram durante esta jornada.

Aos meus grandes amigos, Daniel Gonzalez Maciel e Jann Claude Mousquer, por me acompanharem no caminho da vida profissional.

A todos os professores que fizeram parte desta importante etapa da minha vida.

Aos meus orientadores, Valmei Abreu Júnior e João Paulo de Lima Barbosa, por toda a disponibilidade e orientação.

*"Diggin deep for eternal treasure
Stay away from quicksand and false pleasure."
(Matthew Paul Miller - Matisyahu)*

RESUMO

...

Palavras-chaves: Dados. Data Mining. Twitter. Python.

ABSTRACT

...

Keywords: Data. Data Mining. Twitter. Python.

LISTA DE ILUSTRAÇÕES

FIGURA 1 – Etapas do processo de KDD	24
FIGURA 2 – Exemplo de uma <i>Series</i>	34
FIGURA 3 – Criação de um <i>DataFrame</i>	35
FIGURA 4 – Conteúdo de um <i>DataFrame</i> pelo interpretador <i>IPython</i>	35
FIGURA 5 – Exemplo de um gráfico gerado pelo <i>matplotlib</i>	36
FIGURA 6 – Exemplo de uma página <i>web</i> do <i>IPython Notebook</i>	38
FIGURA 7 – Exemplo de um <i>tweet</i>	43
FIGURA 8 – Aplicação <i>TweetDeck</i> apresentando várias <i>timelines</i>	44
FIGURA 9 – Execução do <i>script</i> para coleta de dados	47
FIGURA 10 – <i>Dirty Data</i> presente no arquivo coletado	52
FIGURA 11 – Utilizando o comando <i>grep</i> para gerar um novo arquivo sem <i>dirty data</i>	52
FIGURA 12 – Línguas que mais realizaram <i>tweets</i>	54
FIGURA 13 – Países que mais realizaram <i>tweets</i>	55
FIGURA 14 – <i>Hashtags</i> com o maior número de <i>tweets</i>	57
FIGURA 15 – Exemplo de <i>links</i> extraídos de <i>tweets</i>	59
FIGURA 16 – Gráfico de setores para figuras importantes	60

LISTA DE TABELAS

TABELA 1 – Cronograma de execução	19
---	----

LISTA DE CÓDIGOS

CÓDIGO 1	Acesso à API do <i>Twitter</i>	45
CÓDIGO 2	<i>Script</i> coletar-hashtags.py	46
CÓDIGO 3	Exemplo de um <i>tweet</i> no formato JSON	47
CÓDIGO 4	Leitura do arquivo JSON	52
CÓDIGO 5	Mapeamento de variáveis para um <i>DataFrame</i>	53
CÓDIGO 6	Contabilização do número de <i>tweets</i> por países	54
CÓDIGO 7	Buscar <i>hashtags</i> mais publicadas	56
CÓDIGO 8	Extração de <i>links</i> provenientes de <i>tweets</i>	58
CÓDIGO 9	Filtro para coletar nomes com mais <i>tweets</i>	58

LISTA DE ABREVIATURAS

API	<i>Application Programming Interface</i> - Interface de Programação de Aplicação
BMP	<i>Windows Bitmap</i>
CGI	<i>Common Gateway Interface</i> - Interface Comum de Entrada ¹
CSV	<i>Comma-Separated Values</i> - Valores Separados Por Vírgula ¹
DBA	<i>Database Administrator</i> - Administrador de Banco de Dados
FTP	<i>File Transfer Protocol</i> - Protocolo de Transferência de Arquivos
GIF	<i>Graphics Interchange Format</i> - Formato Para Intercâmbio de Gráficos ¹
GUI	<i>Graphical User Interface</i> - Interface Gráfica do Usuário
HTTP	<i>Hypertext Transfer Protocol</i> - Protocolo de Transferência de Hipertexto
HTTPS	<i>Hyper Text Transfer Protocol Secure</i> - Protocolo de Transferência de Hipertexto Seguro
IETF	<i>Internet Engineering Task Force</i>
IMAP	<i>Internet Message Access Protocol</i> - Protocolo de Acesso a Mensagem da Internet
IP	<i>Internet Protocol</i> - Protocolo de Internet
JPG	<i>Joint Photographic Experts Group</i>
JSON	<i>JavaScript Object Notation</i> - Notação de Objeto JavaScript ¹
KDD	<i>Knowledge Discovery From Data</i> - Descoberta de Conhecimento por Dados
PDF	<i>Portable Document Format</i> - Formato de Documento Portátil ¹
PNG	<i>Portable Network Graphics</i> - Rede Portável de Gráficos ¹
POP	<i>Post Office Protocol</i> - Protocolo dos Correios

¹ Tradução do autor

RFC	<i>Request for Comments</i> - Pedido Para Comentários
RPC	<i>Remote Procedure Call</i> - Chamada Remota de Procedimento ²
SMTP	<i>Simple Mail Transfer Protocol</i> - Protocolo de Transferência de Correio Simples
SSL	<i>Secure Sockets Layer</i> - Camada Segura de Sockets
SVG	<i>Scalable Vector Graphics</i> - Gráficos Vetoriais Escaláveis
TCP	<i>Transmission Control Protocol</i> - Protocolo de Controle de Transmissão
URI	<i>Uniform Resource Identifier</i> - Identificador Uniforme de Recursos
URL	<i>Uniform Resource Locator</i> - Localizador Padrão de Recursos
XHTML	<i>eXtensible Hypertext Markup Language</i> - Linguagem de Marcação de Hipertexto Extensiva
XML	<i>eXtensible Markup Language</i> - Linguagem de Marcação Extensiva
YML	<i>Yet Another Markup Language</i> - Uma Outra Linguagem de Marcação ²

² Tradução do autor

SUMÁRIO

1	INTRODUÇÃO	15
1.1	JUSTIFICATIVA	17
1.2	OBJETIVOS	18
1.2.1	Objetivo Geral	18
1.2.2	Objetivos Específicos	18
1.3	CRONOGRAMA DE ATIVIDADES	19
1.4	ORGANIZAÇÃO DO TRABALHO	20
2	REVISÃO BIBLIOGRÁFICA	21
3	FUNDAMENTAÇÃO TEÓRICA	23
3.1	DESCOBERTA DE CONHECIMENTO EM BASE DE DADOS E <i>DATA MINING</i>	23
3.2	<i>MACHINE LEARNING</i>	27
3.2.1	<i>Clustering</i>	29
3.2.2	Normalização de Dados	29
3.2.3	Computação de Similaridade	29
3.3	LINGUAGEM PYTHON	29
4	MATERIAIS E MÉTODOS	32
4.1	TECNOLOGIAS E FERRAMENTAS	32
4.1.1	Bibliotecas da Linguagem Python	32
4.1.1.1	<i>Biblioteca NumPy</i>	32
4.1.1.2	<i>Biblioteca pandas</i>	34
4.1.1.3	<i>Biblioteca matplotlib</i>	35
4.1.1.4	<i>Biblioteca SciPy</i>	36
4.1.1.5	Interpretador <i>IPython</i>	37
4.1.2	Interface de Programação de Aplicações - API	38
4.1.2.1	Arquitetura REST	38
4.1.3	Protocolo de Autenticação - OAuth	39
4.1.3.1	Protocolo OAuth 1.0a	40
4.1.3.2	Protocolo OAuth 2.0	41
4.1.4	Rede Social <i>Twitter</i>	41
4.1.4.1	API do <i>Twitter</i>	42
4.1.4.2	Bibliotecas Para o Consumo de Dados da API do <i>Twitter</i>	44
4.2	METODOLOGIA E DESENVOLVIMENTO	45
4.2.1	Iterativo e Incremental	45
5	IMPLEMENTAÇÃO DAS TÉCNICAS E ANÁLISE DOS RESULTADOS	46

5.1	COLETA DE DADOS	46
5.2	ANÁLISE DE DADOS	51
6	CONCLUSÕES E SUGESTÕES PARA FUTUROS TRABALHOS . .	61
6.1	CONCLUSÕES	61
6.2	SUGESTÕES PARA FUTUROS TRABALHOS	61
	REFERÊNCIAS	62

1 INTRODUÇÃO

Redes sociais se tornaram um termo comum e uma chave fundamental para o estilo de vida moderno. Hoje em dia, a maioria das pessoas, independente de idade, sexo, crença, utilizam uma ou mais redes sociais. A princípio, esses ambientes *on-line* focavam-se na comunicação, por exemplo; a possibilidade de se comunicar com alguém distante e tornar esse diálogo pessoal, seguro e, de alguma forma, próximo, ajudando na popularização desse tipo de tecnologia. No decorrer dos anos e com o avanço tecnológico, diferentes tipos de redes sociais surgiram com ideias semelhantes ou extremamente diferentes, não sendo apenas para a comunicação, mas para outros fins como o compartilhamento de mídias, localização, críticas, *mini-blogs*, perguntas e respostas, negócios, profissão, música, artes, venda e troca de produtos, entre outros.

Facebook, *Twitter*, *LinkedIn*, *Google+* e, muito comum entre desenvolvedores, o *GitHub* são exemplos populares de redes sociais. Logo, possuem grande número de usuários e diversas interações que estes realizam a cada momento, gerando uma quantidade gigantesca de dados. Esses dados são informações sobre pessoas, comportamentos, gostos, marcas e vários outros tipos de conteúdo. Devido a diversidade e a vasta quantidade desse tipo de informação, algumas redes sociais as utilizam para o aprimoramento de conteúdo ou, então, para o comércio de dados para empresas, por exemplo; de publicidade e marketing, que fazem a mineração desses dados para encontrar padrões de seus usuários e, assim, conseguir aumentar suas vendas, reduzir riscos e, até mesmo, gerar novas tendências.

Dados é um termo, deliberadamente vago, que agrega várias formas comuns de informações, como por exemplo matrizes (vetores multidimensionais), tabelas ou planilhas, onde cada coluna pode ter um tipo diferente de informação (caracteres, numéricos, data, entre outros). Essas tabelas podem se relacionar através de colunas chaves apresentada no modelo relacional de Codd (1969 apud JANSSENS, 2014).

Certamente que todos esses exemplos citados não demonstram a totalidade e nem toda a abordagem para a palavra dados. Não é sempre que grande percentual de um conjunto de dados pode ser transformados em uma forma estruturada, onde é possível serem analisados e modelados.

Cientistas de dados precisam visualizá-los com o objetivo de produzir resultados claros e serem capazes de informar ao seus mantenedores sobre a situação atual e a qualquer momento. Este é o verdadeiro valor que um cientista nessa área precisa prover.

A mineração de dados, também conhecida como *data mining*, é o processo de

analisar dados em diferentes perspectivas e transformar em informação útil. Hoje em dia, o *data mining* é usado por companhias com grande foco em varejo, finanças, comunicação e marketing, para conseguirem determinar as relações de fatores internos como preço, posição de produto, ou habilidade de recurso humano, e fatores externos como indicadores econômicos, competições e população demográfica de clientes (RUSSELL, 2013).

Essa análise de dados consiste em visualizar informações em diferentes maneiras e formas, plotando gráficos e planilhas. Com isso, novas informações aparecerão permitindo alguma previsão ou predição desse conteúdo. As observações levarão a uma reflexão que resultará em possibilidades ou probabilidades concretas para se exercer uma atividade. No primeiro momento, essas informações são amorfas e, após a análise, se transformará em ideias (HAN et al., 2012).

Para que essas ideias se tornem um trabalho futuro é preciso capturá-las e interpretá-las através de um modelo de extração de conhecimento. Esse modelo, geralmente, é um processo que apresenta etapas que vão do armazenamento dos dados em estudos até processos matemáticos, estatísticos e computacionais, com o objetivo de extrair informações úteis. Um modelo então, é muito mais que apenas a descrição dos dados, incorpora o entendimento de todo o processo da origem dos dados até a competência deles. Logo, ele consegue fazer previsões sobre os conhecimentos analisados (HAN et al., 2012).

Para conseguir fazer melhores previsões é preciso desenvolver métodos mais sofisticados antes de formular um modelo relevante. Com isso, a dificuldade aumenta e, então, é necessário implementar um modelo computacional que consiga obter possíveis resultados através do reconhecimento desses dados.

Para a análise e a interação de dados, computação exploratória e visualização de dados, a linguagem de programação Python vai, inevitavelmente, ser comparada a muitas outras, tanto no domínio de software livre, como também, com linguagens e ferramentas comerciais, como R, MATLAB, SAS, Stata e outros. Atualmente, o Python possui bibliotecas que se tornaram fortes alternativas para a tarefa de manipulação de dados. Combinado com o poder de programação que a linguagem tem, é uma excelente escolha como linguagem para a construção de aplicações centradas em dados (MCKINNEY, 2013).

Em muitas organizações, é comum realizar pesquisas, prototipar e testar novas ideias utilizando mais de um domínio específico de linguagem computacional, como MATLAB ou R e, posteriormente, estas ideias viram parte de um sistema de produção maior, escrito, por exemplo, em Java, C#, ou C++. Kaldero (2015), afirma que Python não é somente uma linguagem adequada para a pesquisa e prototipagem, mas também para o desenvolvimento de sistemas.

Devido a esta solução de apenas uma única linguagem, as organizações podem se beneficiar, tendo cientistas e tecnólogos usando o mesmo conjunto de ferramentas programáticas. Portanto, Python é a ferramenta escolhida pela maioria desses profissionais. Essa escolha se deve, não somente a alta produtividade que a linguagem fornece, mas também por ela ser uma ferramenta comum a diferentes times e organizações (KALDERO, 2015).

Python é uma linguagem de programação livre e multiplataforma, possui uma excelente documentação e está sobre cuidado de uma enorme comunidade, onde é possível obter ajuda e melhores soluções para problemas durante a codificação. Tem como grande vantagem a facilidade de aprendizado, porque foi desenvolvida para ser simples e descomplicada. É uma linguagem interpretada, dinamicamente tipada, com grande precisão e sintaxe eficiente. Tem grande popularidade para analisar dados devido ao enorme poder que suas bibliotecas possuem (*NumPy*, *SciPy*, *pandas*, *matplotlib*, *IPython*). A linguagem apresenta alta produtividade para prototipação, desenvolvimento de sistemas menores e reaproveitáveis.

A mineração de dados busca então, extrair dos dados o conhecimento útil para algum objetivo específico. Entretanto, a tarefa de extração de conhecimento é complexa devido a multidisciplinaridade envolvida no seu processo de extração e, também, por não ter um modelo de mineração genérico para a busca de informação útil. Para isso, é necessário o uso de ferramentas que viabilizam essas tarefas. Logo, Python dispõe de um conjunto de bibliotecas para a análise e mineração de dados extremamente poderosas e com uma curva de aprendizado curta, graças a sintaxe clara e descomplicada que a linguagem fornece.

1.1 JUSTIFICATIVA

A rede social *Twitter* é um excelente ponto de partida para a mineração de dados em redes sociais. Devido a sua abertura ao público para o consumo de informações, uma API bem documentada e vasta quantidade de dados devido a interação dos usuários a todo instante. Os dados do *Twitter* são particularmente interessante, porque *tweets*, frases postadas nesta rede social, acontecem, segundo Russell (2013), na "velocidade do pensamento" e logo estão disponíveis na Internet.

Esta disponibilidade de dados em tempo real, permite que os usuários possam comentar e interagir com outras pessoas sobre acontecimentos atuais e de uma forma instantânea. Logo, é possível acompanhar o *Twitter* com a finalidade de ter informações sobre qualquer tipo de notícia que esteja acontecendo no mundo, desde que estes fatos sejam publicados na rede social.

Atualmente o Brasil está passando por alguns eventos importantes que, conse-

quentemente, tem gerado muitos *tweets* devido a sua relevância. Em virtude de vários episódios de crimes fiscais, corrupção, lavagem de dinheiro, a falta de atenção em alguns setores públicos, e como resultado, diversas manifestações da população, um processo de Impeachment da presidente Dilma Rouseff foi iniciado.

Muitos brasileiros tem se manifestado em diversas redes sociais, e o *Twitter* é uma ótima escolha, graças a sua velocidade de comunicação e propagação de notícias. Estes *tweets* sobre a atual situação política, apresentam comentários de ambos os lados do processo de Impeachment, aqueles que são a favor e os contrários a esta decisão.

É de interesse, então, a mineração destes dados já que a rede social *Twitter* dispõe de uma vasta quantidade de informações. A cada segundo, 9.100 *tweets* são publicados, e atingem um bilhão a cada 5 dias. A rede social possui um total de 289 milhões de usuários ativos no mundo inteiro, totalizando 58 milhões de *tweets* por dia (BRAIN, 2016).

Minerar e analisar os *tweets* em dias de decisões políticas, resultará em novas informações e entendimentos sobre as escolhas e pensamentos populares quanto ao governo brasileiro. Através da linguagem de programação Python, é possível coletar e analisar estes dados utilizando bibliotecas específicas para a manipulação e consumo de informações de redes sociais, inclusive o *Twitter*.

1.2 OBJETIVOS

1.2.1 Objetivo Geral

Este trabalho tem como objetivo principal utilizar técnicas e algoritmos de *data mining*, como o aprendizado de máquina (*machine learning*), para a análise e mineração de dados provenientes da rede social *Twitter*, utilizando os recursos e bibliotecas que a linguagem de programação Python possui.

1.2.2 Objetivos Específicos

- Identificar os conceitos sobre KDD e *data mining*;
- Descrever as técnicas de *data mining*;
- Explorar as funcionalidades das bibliotecas de mineração e visualização da linguagem Python;
- Examinar e utilizar a API da rede social *Twitter* para a coleta de dados;
- Encontrar padrões em dados provenientes do *Twitter*, utilizando técnicas e algoritmos de aprendizado de máquina (*machine learning*);

- Compreender e aplicar técnicas de geolocalização para melhor visualização e apresentação de resultados;
- Apresentar testes e resultados obtidos da análise e mineração dos dados.

1.3 CRONOGRAMA DE ATIVIDADES

As atividades a serem executadas no decorrer do projeto visando o êxito do mesmo, estão listados a seguir e especificados em meses na Tabela 1:

- Estudo e Pesquisa: aquisição dos conhecimentos pertinentes e necessários para o desenvolvimento do projeto;
- Análise de Requisitos: levantamento dos requisitos do projeto;
- Geração do Documento: desenvolvimento das documentações para especificação do projeto;
- Implementação: desenvolvimento dos códigos para a análise de dados;
- Testes: execução dos testes que irão garantir a qualidade das informações a serem geradas;
- Elaboração de Artigos: parte do tempo destinado ao projeto será para desenvolver artigos visando a publicação em eventos da área;
- Apresentação de Resultados: etapas destinadas à apresentação dos resultados parciais e finais.

TABELA 1: Cronograma de execução

Mês - Ano	08/15	09/15	10/15	11/15	12/15	02/16	03/16	04/16	05/16
Estudo e Pesquisa	X	X	X	X	X	X	X	X	
Análise de Requisitos	X	X	X	X	X	X	X	X	
Geração do Documento	X	X	X	X	X	X	X	X	X
Implementação				X	X	X	X	X	X
Testes				X	X	X	X	X	X
Elaboração de Artigos			X	X	X			X	X
Apresentação de Resultados					X				X

FONTE: Elaborado pelo autor

1.4 ORGANIZAÇÃO DO TRABALHO

Além deste capítulo introdutório, este trabalho é composto de mais seis capítulos.

O Capítulo 2 apresenta os trabalhos que são referências para este estudo.

Os fundamentos teóricos, como os conceitos de *data mining*, e base para o entendimento do tema proposto estão descritos no Capítulo 3.

As bibliotecas da linguagem Python utilizadas para a mineração de dados são expostas no Capítulo 4. Também, são apresentadas neste capítulo a API do *Twitter*, as etapas de *data mining* e outros materiais e metodologias utilizados para execução deste trabalho.

No Capítulo 5 são demonstradas as fases do desenvolvimento de *scripts* para a coleta e obtenção de resultados, assim como a utilização de técnicas de *machine learning*.

Os resultados obtidos e a apresentação de planilhas e gráficos das soluções desenvolvidas também são apresentados no Capítulo 5, devido a disponibilidade desses, logo após a execução dos *scripts*.

Por fim, a conclusão deste trabalho se dá no Capítulo 6, onde são abordadas e analisadas as dificuldades, além de determinar as possibilidades para trabalhos futuros.

2 REVISÃO BIBLIOGRÁFICA

Alguns trabalhos serviram como ajuda e inspiração para este estudo. Porém durante o período de busca por bibliografias a respeito de *data mining*, pouco material foi encontrado quanto a mineração em redes sociais. Ainda sim, alguns estudos possuem um destaque e é necessário citá-los, devido a utilização de ferramentas específicas em *data mining* e, também, aos resultados obtidos neste processo.

De acordo com Lemos (2003), um dado se transforma em informação quando ganha um significado para seu utilizador, caso contrário, continua sendo simplesmente um dado.

Em seu estudo, Lemos (2003) aborda duas técnicas de *data mining*: Árvores de Decisão e Redes Neurais, para realizar a análise de crédito bancário. Estas técnicas permitem fazer o reconhecimento de padrões e também diagnosticar novos casos. Através deste modo, os analistas têm condições de diagnosticar os novos clientes, quanto ao merecimento de crédito ou não. Estas técnicas de mineração de dados são ferramentas que podem ser utilizadas pelo especialista para auxiliá-lo nas tomadas de decisão, nunca porém poderão por si só, substituir a figura do especialista no contexto da análise de crédito.

Semelhante as técnicas abordadas para a análise de crédito bancário, Steiner et al. (2004) realizaram um estudo na área médica, onde a posse e uso de ferramentas que auxiliem na tarefa de classificação de pacientes em prováveis ictéricos com câncer ou ictéricos com cálculo, pode ser crucial. Em uma tentativa de otimizar todo o processo do diagnóstico, minimizando riscos e custos e, por outro lado, maximizando a eficácia nos resultados, utilizaram técnicas de *data mining* como um processo para extração de informações valiosas. O trabalho consistiu na análise de 118 históricos de pacientes utilizando Árvores de Decisão e Regras de Classificação como ferramenta. Os autores afirmam que os métodos de *data mining* apresentam a vantagem de deixar claro ao usuário quais são os atributos que estão discriminando os padrões e de que forma a mesma está ocorrendo, isso é uma característica altamente desejável em qualquer técnica de reconhecimento de padrões.

O reconhecimento de padrões permite a obtenção de conhecimento da frequência com que determinadas seções de uma página *web* são acessadas e quais são os serviços mais procurados. Isso possibilita que empresas consigam descobrir o perfil de seus usuários e, com base nesse acontecimento, ofertar serviços e atendimento personalizado. Essa afirmação foi resultado do estudo de Silva, Boscarioli e Peres (2003), onde realizaram a mineração de dados em *logs* de acesso a servidores *web*.

Para o desenvolvimento do trabalho utilizaram regras de associação para a descoberta e representação de padrões frequentes em conjuntos de dados. Isso propiciou a identificação de padrões de comportamento de usuários da Internet ao navegarem por *websites*. Também concluem que outras ferramentas de mineração podem ser aplicadas, visando aumentar a flexibilidade de manipulação dos atributos específicos para o ambiente *Web*.

Como visto, o tema sobre *data mining* possui uma abordagem comum a setores e áreas diferentes, o que caracteriza a enorme quantidade de dados que ainda não se tem informação útil para seus utilizadores. Por mais que as técnicas utilizadas dentre essa diversidade de áreas sejam semelhantes, o desenvolvimento e aplicação das técnicas são particulares para cada caso. Neste contexto, esta dissertação modela, de uma forma mais simplificada, o reconhecimento de padrões para a predição dos dados extraídos da rede social *Twitter*.

3 FUNDAMENTAÇÃO TEÓRICA

A mineração de dados é um assunto totalmente interdisciplinar, podendo ser definido de diversas maneiras. Até mesmo o termo *data mining* não representa realmente todos os componentes desta área. Han et al. (2012) exemplificam esta questão comentando sobre a mineração de ouro através da extração de rocha e areia, que é chamado de mineração de ouro e não mineração de rochas ou mineração de areia. Analogamente, a mineração de dados deveria se chamar "mineração de conhecimento através de dados" que, infelizmente, é um termo um tanto longo. Entretanto, uma referência mais curta, como "mineração de conhecimento", pode não enfatizar a mineração de uma enorme quantidade de dados. Apesar disso, a mineração é um termo que caracteriza o processo de encontrar uma pequena quantidade de uma preciosa pepita em uma grande quantidade de matéria bruta. Nesse sentido, um termo impróprio contendo ambos "*data*" e "*mining*" se tornou popular e, como consequência, muitos outros nomes similares surgiram: *knowledge mining from data*, *knowledge extraction*, *data/pattern analysis*, *data archaeology* e *data dredging*.

Na seção 3.1 será abordado os conceitos de descoberta de conhecimento em base de dados e a sua diferença em relação ao *data mining*. Logo após a explicação desta distinção, será apresentado os métodos e a concepção de *data mining*. Alguns desses métodos tem como prática o uso de aprendizado de máquina, que será definido na seção 3.2. A seção 3.3 irá caracterizar a linguagem de programação Python e qual a sua vantagem em utilizá-la para a mineração de dados.

3.1 DESCOBERTA DE CONHECIMENTO EM BASE DE DADOS E *DATA MINING*

Muitas pessoas tratam a mineração de dados como um sinônimo para outro termo muito popular, descoberta de conhecimento em base de dados (*knowledge discovery from data*) - KDD, enquanto outros referenciam *data mining* como apenas uma etapa no processo de descoberta de conhecimento em base de dados. O processo de KDD é demonstrado através da Figura 1 e, posteriormente, listada como uma sequência interativa e iterativa dos seguintes passos:




FIGURA 1: Etapas do processo de KDD

FONTE: Adaptado de Han et al. (2012)

1. *Data cleaning* (Limpeza de dados);
2. *Data integration* (Integração de dados);
3. *Data selection* (Seleção de dados);
4. *Data transformation* (Transformação de dados);
5. *Data mining* (Mineração de dados);
6. *Pattern evaluation* (Avaliação de padrões);
7. *Knowledge presentation* (Apresentação de conhecimento).

É importante notar que algum dos processos acontecem na mesma etapa: Limpeza e integração; Seleção e transformação; Avaliação e apresentação.

De acordo com Brachman et al. (1996 apud FAYYAD et al., 1996-b), as etapas são interativas porque envolvem a cooperação da pessoa responsável pela análise de dados, cujo conhecimento sobre o domínio orientará a execução do processo. Por sua vez, a interação deve-se ao fato de que, com frequência, esse processo não é executado de forma sequencial, mas envolve repetidas seleções de parâmetros e conjuntos de dados, aplicações das técnicas de *data mining* e posterior análise dos resultados obtidos, a fim de refinar os conhecimentos extraídos.

KDD refere-se ao processo global de descobrimento de conhecimento útil em bases de dados. *Data mining* é um passo particular neste processo de aplicação de algoritmos específicos para extrair padrões (modelos) de dados. Os passos adicionais no processo KDD, como integração de dados, limpeza, seleção e transformação dos dados, assim como a interpretação e a apresentação dos resultados, asseguram que o conhecimento útil (informação) foi descoberto provenientes da etapa de mineração (HAN et al., 2012). A aplicação cega de métodos de *data mining*, conforme alertado por Navega (2002), pode ser uma atividade perigosa que conduz a descoberta de padrões sem sentido.

O KDD evoluiu e continua evoluindo da interseção de pesquisas em campos como bancos de dados, aprendizado de máquinas (*machine learning*), reconhecimento de padrões, estatísticas, inteligência artificial, aquisição de conhecimento para sistemas especialistas, visualização de dados, descoberta científica, recuperação de informação e computação de alto-desempenho. Aplicações de KDD incorporam teorias, algoritmos e métodos de todos estes campos (LEMOS, 2003).

Apesar do conceito de *data mining*, na maioria das vezes, ser utilizado pelas indústrias, mídias e centros de pesquisa para se referir ao processo de descoberta de conhecimento considerado em sua globalidade, o termo *data mining* pode ser usado

também para indicar o quinto estágio do KDD, sendo um processo essencial na descoberta e extração de padrões de dados. Han et al. (2012), adotam uma visão mais abrangente para a funcionalidade de mineração de dados: *data mining* é o processo de descoberta de padrões interessantes e conhecimentos de um vasto conjunto de dados. A fonte dos dados pode ser banco de dados, *data warehouses*, a Internet, outros repositórios de informações, ou dados correntes em sistemas dinâmicos.

Uma das definições, talvez, mais importante de *data mining* foi elaborada por Fayyad et al. (1996-a) "...o processo não-trivial de identificar, em dados, padrões válidos, novos, potencialmente úteis e ultimamente compreensíveis".

Data mining ou mineração de dados, pode ser entendido então, como o processo de extrair informação, ou conhecimento útil, de algum conjunto de dados e utilizar este conhecimento adquirido para tomada de decisões ou descrever características e padrões descobertos (SFERRA; CORREA, 2003).

Diversos métodos são usados em *data mining* para encontrar respostas ou extrair conhecimento interessante. Esses podem ser obtidos através dos seguintes métodos:

- Classificação: associa ou classifica um item a uma ou várias classes. Os objetivos dessa técnica envolvem a descrição gráfica ou algébrica das características diferenciais das observações de várias populações. A ideia principal é derivar uma regra que possa ser usada para classificar, de forma otimizada, uma nova observação a uma classe já rotulada;
- Modelos de Relacionamento entre Variáveis: associa um item a uma ou mais variáveis de predição de valores reais, conhecidas como variáveis independentes ou exploratórias. Nesta etapa se destacam algumas técnicas estatísticas como regressão linear simples, múltipla e modelos lineares por transformações, com o objetivo de verificar o relacionamento funcional entre duas variáveis quantitativas, ou seja, constatar se há uma relação funcional entre X e Y;
- Análise de Agrupamento (*Cluster*): associa um item a uma ou várias classes (ou *clusters*). Os *clusters* são definidos por meio do agrupamento de dados baseados em modelos probabilísticos ou medidas de similaridade. Analisar *clusters* é uma técnica com o objetivo de detectar a existência de diferentes grupos dentro de um determinado conjunto de dados e, caso exista, determinar quais são eles;
- Sumarização: determina uma descrição compacta para um determinado subconjunto, por exemplos; medidas de posição e variabilidade. Nesta etapa se aplica

algumas funções mais sofisticadas envolvendo técnicas de visualização e a determinação de relações funcionais entre variáveis. Estas funções são usadas para a geração automatizada de relatórios, sendo responsáveis pela descrição compacta de um conjunto de dados;

- **Modelo de Dependência:** descreve dependências significativas entre variáveis. Estes modelos existem em dois níveis: estruturado e quantitativo. O nível estruturado demonstra, através de gráficos, quais variáveis são localmente dependentes. O nível quantitativo especifica o grau de dependência utilizando alguma escala numérica;
- **Regras de Associação:** determinam relações entre campos de um banco de dados. Esta relação é a derivação de correlações multivariadas que permitam auxiliar as tomadas de decisão. Medidas estatísticas, como correlação e testes de hipóteses apropriados, revelam a frequência de uma regra no universo dos dados minerados;
- **Análise de Séries Temporais:** determina características sequenciais, como dados com dependência no tempo. Tem como objetivo modelar o estado do processo extraíndo e registrando desvios e tendências no tempo. As séries são compostas por quatro padrões: tendência, variações cíclicas, variações sazonais e variações irregulares. Existem vários modelos estatísticos que podem ser aplicados a essas situações.

A maioria destes métodos são baseados em técnicas de aprendizado de máquina (*machine learning*), reconhecimento de padrões e estatística. Essas técnicas vão desde estatística multivariada, como análise de agrupamentos e regressões, até modelos mais atuais de aprendizagem, como redes neurais, lógica difusa e algoritmos genéticos (SFERRA; CORREA, 2003).

Devido aos vários métodos estatísticos que são aplicados no processo de *data mining*, Fayyad et al. (1996-a) mostram uma relevância da estatística para o processo de extração de conhecimentos ao afirmar que essa ciência provê uma linguagem e uma estrutura para quantificar a incerteza resultante quando se tenta deduzir padrões de uma amostra a partir de uma população.

3.2 MACHINE LEARNING

Abstratamente, pode-se pensar em *machine learning*, ou aprendizado de máquina, como um conjunto de ferramentas e métodos que tentam inferir padrões e extrair *insights* de uma porção daquilo que se é observado no mundo. Por exemplo, ao

tentar ensinar um computador a reconhecer os códigos postais escritos nos envelopes, os dados podem consistir em fotografias dos envelopes, além de um registro do código postal a que cada envelope estava endereçado, ou seja, dentro de um contexto, é possível selecionar um registro de ações de certos objetos, aprender com este registro e, em seguida, criar um modelo dessas atividades que irão informar a compreensão deste contexto futuramente (CONWAY; WHITE, 2012).

Na prática, isto requer dados e, em aplicações atuais, isso, muitas vezes, significa uma grande quantidade de dados (talvez vários *terabytes*). A maioria das técnicas de aprendizagem automática considera a disponibilidade de tais dados como algo inquestionável, o que significa novas oportunidades para a sua aplicação, em função da quantidade de dados que são produzidos como um produto de administrar companhias modernas.

Machine learning é a intersecção entre ciência da computação, engenharia, estatística e outras disciplinas. É possível ser aplicada em várias áreas, desde políticas a geociência. É uma ferramenta que pode ser utilizada para a solução de vários problemas. Qualquer campo que precisa interpretar e agir sobre dados pode se beneficiar do uso de técnicas de *machine learning* (CONWAY; WHITE, 2012).

A prática de engenharia está em utilizar a ciência para resolver um problema. Em engenharia, é comum resolver um problema determinista, em que a solução dada por humanos sempre resolve o problema. Se desenvolver um software para controlar uma máquina de venda automática é melhor que esta trabalhe sempre, independentemente do dinheiro depositado ou dos botões pressionados. Muitos problemas existem quando a solução não é determinista, isto é, ou não se sabe o suficiente sobre o problema ou não se tem poder computacional suficiente para delineá-lo adequadamente. Para esses problemas, precisa-se de estatísticas.

Uma das tarefas de *machine learning* é a classificação. Na classificação, o trabalho é prever em que classe deve uma porção de dados ser enquadrada. Outra tarefa é a regressão que é a previsão de um valor numérico. Classificação e regressão são exemplos de aprendizado supervisionado, que são conhecidos como supervisionado, por dizer o que o algoritmo deve prever (HARRINGTON, 2012).

O oposto de aprendizagem supervisionada é um conjunto de tarefas conhecidas como aprendizado não supervisionado, onde não há nenhum rótulo ou valor alvo dado para os dados. Uma solução para este tipo de aprendizagem é o agrupamento de itens semelhantes denominado de *clustering*. Na aprendizagem não supervisionada, também pode-se querer encontrar valores estatísticos que descrevem os dados. Isso é conhecido como estimativa da densidade. Outra tarefa do aprendizado não supervisionado está em reduzir dados com várias funcionalidades até se chegar a um número reduzido, em que seja possível visualizá-lo em duas ou três dimensões (HARRING-

TON, 2012).

3.2.1 *Clustering*

A técnica de *clustering* é um aprendizado não supervisionado que está presente em várias ferramentas de *data mining*. Consiste na adoção de uma coleção de itens e, após particioná-los em pequenas coleções, conhecidos como *cluster*, baseando-se em alguma heurística que será usada para comparar com outros itens da coleção.

Técnicas para *clustering* são partes fundamentais para um processo de mineração de dados. Uma implementação simples de *clustering* pode criar experiências de usuário incrivelmente convincentes para alcançar resultados. Também pode ser aplicado a bases de texto utilizando algoritmos de *text mining*, onde o algoritmo procura agrupar textos que falem sobre o mesmo assunto e separar textos de conteúdo diferentes.

Por exemplo, caso queira considerar a localização geográfica dos contatos na rede *Twitter*, é necessário realizar um *cluster* nas conexões através de um determinado número de regiões com o intuito da melhor compreensão de oportunidades econômicas disponíveis.

3.2.2 Normalização de Dados

A normalização de dados, procura então resolver esses problemas padronizando situações específicas que irá facilitar a análise posterior dos dados.

3.2.3 Computação de Similaridade

Após a normalização dos itens, é preciso verificar a similaridade entre eles. Podendo ser vagas de emprego, nomes de empresas, interesses profissionais, indicação geográfica, ou qualquer outro campo digitado na busca como um texto livre. Para isso é necessário definir uma heurística que conseguirá aproximar a similaridade entre dois valores quaisquer. Em algumas situações a similaridade heurística será um tanto óbvia, porém em outros casos será complicada. Por exemplo, comparar o tempo de carreira entre duas pessoas pode ser simples como uma operação de soma ou subtração. Mas comparar um elemento profissional, como "atitude de liderança" de uma maneira automatizada pode ser um desafio.

3.3 LINGUAGEM PYTHON

Python é uma linguagem de programação orientada a objetos, interpretada e interativa. Incorpora módulos, exceções e de tipagem dinâmica alta. Possui uma sintaxe clara e simples, o que facilita o aprendizado para novos desenvolvedores, assim

como a rápida leitura e interpretação para usuários mais experientes. Dispõe de interfaces para várias chamadas de sistemas (*system calls*) e bibliotecas, também para vários sistemas de janelas, e é extensível a outras linguagens de programação como C ou C++. É também usada como uma linguagem de extensão para aplicações que precisam de uma interface programática (PYTHON, 2015).

Outra característica da linguagem Python é a portabilidade, podendo ser utilizada em diversos sistemas operacionais como variantes do Unix, em sistemas Mac e também em PCs sob MS-DOS, Windows, Windows-NT, e OS/2.

É uma linguagem de programação de alto-nível que pode ser aplicada em soluções para diversas classes diferentes. Possui uma vasta quantidade de bibliotecas que atende a áreas como o processamento de *strings* (expressões regulares, Unicode, cálculo de diferença entre arquivos), protocolos de Internet (HTTP, FTP, SMTP, XML-RPC, POP, IMAP, CGI *programming*), engenharia de software (testes unitários, registro de logs, *profiling*, análise de código Python), e interfaces para sistemas operacionais (*system calls*, sistemas de arquivos, TCP/IP *sockets*) (PYTHON, 2015).

A sintaxe bastante expressiva e a abundância de suas bibliotecas tornam Python uma ótima linguagem para se obter resultados em várias questões. Algumas de suas utilidades são apresentadas conforme a seguinte lista:

- Escrita de *scripts*: Python é uma ótima linguagem para a criação de *scripts*. É possível usar *scripts* para analisar arquivos de texto, gerar amostra de entradas para testar programas, coletar conteúdos de páginas *web* utilizando a biblioteca *Beautiful Soup*, dentre outras atividades;
- Desenvolvimento *backend* para aplicações *web*: É possível criar APIs (*Application Programming Interface*, apresentado no capítulo 4) e interagir com banco de dados. *Frameworks* mais utilizados inclui *Django*, *Flask* e *Pyramid*;
- Análise e visualização de dados: Conforme o foco deste trabalho, bibliotecas como *pandas*, *NumPy* e recursos semelhantes a outras ferramentas como R e MATLAB estão dispostas através da biblioteca *SciPy*;
- *matplotlib* e *Seaborn*: são mecanismos que possibilitam a visualização dos dados.

A utilização dessa linguagem como ferramenta principal para este trabalho se justifica na utilização dos pacotes que facilitam a análise e interpretação de dados. Como exemplo, *NumPy*, *SciPy*, *pandas*, *matplotlib* e *IPython* são os mecanismos indispensáveis para a mineração de informações juntamente com as estruturas de dados já presentes em Python como os *dictionaries* (estruturas similares ao JSON), que

permitem ordenar dados através de um modelo chave-valor. Devido então a sintaxe intuitiva que a linguagem possui e seu excelente ecossistema de bibliotecas, é possível acessar APIs e manipular dados com mais facilidade (RUSSELL, 2013).

4 MATERIAIS E MÉTODOS

Após a revisão bibliográfica de outros estudos e os fundamentos teóricos necessários para a mineração de dados utilizando Python, torna-se importante definir as ferramentas, tecnologias e procedimentos necessários para o desenvolvimento do projeto.

Este capítulo apresenta os materiais e métodos utilizados para a realização do processo de *data mining*, onde, na seção 4.1 são apresentadas as tecnologias e ferramentas que serão utilizadas durante o estudo. Serão abordados quais as bibliotecas que a linguagem Python disponibiliza para a análise e mineração de dados e, também, como acessar a API do *Twitter*. Esta será esclarecida também neste capítulo, após a explicação do conceito de API e o protocolo OAuth.

A seção 4.2 irá concluir o capítulo apresentando as etapas de *data mining* com o intuito de evidenciar o processo para a obtenção de conhecimento útil.

4.1 TECNOLOGIAS E FERRAMENTAS

Tecnologias e ferramentas para a criação e prototipagem dos algoritmos.

4.1.1 Bibliotecas da Linguagem Python

Um dos grandes diferenciais da linguagem Python é o seu enorme conjunto de bibliotecas para soluções de diversos problemas.

A seguir serão apresentadas as bibliotecas necessárias para a mineração de dados, através das quais é possível coletar, limpar, transformar, realizar operações e apresentar resultados proveniente dos dados da rede social *Twitter*. Para evitar repetições da palavra "biblioteca", o termo "pacote" também será utilizado com o mesmo significado no restante desta dissertação.

4.1.1.1 Biblioteca NumPy

NumPy é o pacote fundamental para computação científica em Python. É o acrônimo para *Numerical Python*. Esta biblioteca provê:

- *ndarray* que é um objeto de matriz multidimensional;
- Funções que permitem realizar operações vetoriais ou operações matemáticas entre matrizes sem a necessidade de programar *loops*;
- Ferramentas para a leitura e escrita em conjuntos de dados matriciais;

- Operações de álgebra linear, transformada de Fourier e geração de números aleatórios;
- Ferramentas para a integração em outras linguagens de programação como C, C++ e Fortran.

Além da capacidade de rápido processamento em matrizes que o *NumPy* oferece ao Python, um dos principais objetivos em relação a análise de dados é que serve como um "container" para os dados serem passado por algoritmos. Para dados numéricos, as matrizes de *NumPy* são muito mais eficientes para a ordenação e manipulação de dados do que qualquer outra estrutura embutida em Python. Igualmente, bibliotecas escritas em linguagens de baixo nível, como C ou Fortran, podem operar dados gravados em matrizes da *NumPy* sem precisar da cópia de qualquer dado (MCKINNEY, 2013).

A biblioteca *NumPy* por si só, não provê uma funcionalidade de alto-nível para a análise de dados. Tendo um conhecimento sobre as matrizes de *NumPy* e matrizes orientadas a computação (*array-oriented computing*) irá facilitar o uso de outras ferramentas, como *pandas*, com mais efetividade.

Para aplicações voltadas para a análise de dados, esta biblioteca possui grande funcionalidade em setores como:

- Criação rápida de matrizes para a interação e limpeza de dados, separação e filtragem, transformação e outros tipos de operações computacionais;
- Algoritmos comuns para matrizes como ordenação, operações únicas e definidas;
- Eficiente descrição estatística e agregação/sumarização de dados;
- Alinhamento de dados e manipulação de dados relacionais para operações de junção e imerção (*join* e *merge*) de conjuntos de dados heterogeneos;
- Expressar lógicas de condições através de expressões matriciais ao invés de laços de repetições e condições como *while*, *for*, *if-elif-else*;
- Agrupamento de manipulação de dados (agregação, transformação, aplicação de funções).

Enquanto *NumPy* oferece o fundamento computacional para essas operações, é preferível utilizar a biblioteca *pandas* como base para a mineração de dados (especialmente de dados estruturados ou dados tabulados), devido a sua interface rica e de alto-nível no qual permite as tarefas com dados mais concisas e simples.

4.1.1.2 Biblioteca *pandas*

A biblioteca *pandas* atrai o maior interesse de cientistas quanto a mineração de dados. Ela possui estruturas de dados de alto-nível e ferramentas de manipulação desenvolvidas para facilitar e agilizar a análise de dados em Python. *pandas* é desenvolvida sob a biblioteca *NumPy* e viabiliza o uso em aplicações centradas nesta. A seguir são expostas algumas soluções que a biblioteca disponibiliza (MCKINNEY, 2013):

- Estrutura de dados com eixos rotulados suportam o alinhamento de dados automáticos ou explícitos. Isso evita erros comuns resultantes de dados desalinhados e dados indexados de formas diferentes provenientes de outras fontes de dados;
- A mesma estrutura de dados consegue manusear tanto dados de séries temporais como dados não-temporais;
- Operações e reduções aritméticas é passado para metadados (eixos rotulados);
- Manipulação flexível de dados em falta;
- *Merge* (fundir) e outras operações relacionais encontradas em bancos de dados relacional.

Esta biblioteca possui duas estrutura de dados principais: *Series* e *DataFrame*. Estas estruturas não são uma solução universal para todos os problemas, mas provê uma base sólida e de fácil manipulação para a maioria das aplicações com mineração de dados.

Uma *Series* é um tipo de *array* ou uma matriz unidimensional, similar a um *array* que possui uma matriz de dados (qualquer tipo de dado da biblioteca *NumPy*) e um outro vetor associado a dados rotulados, chamados de *index* (índice). Uma simples *Series* é formado por uma única matriz de dados, conforme a Figura 2.

```
[In [5]: obj = Series([4, 7, -5, 3])  
  
[In [6]: obj  
Out[6]:  
0      4  
1      7  
2     -5  
3      3  
dtype: int64
```

FIGURA 2: Exemplo de uma *Series*

FONTE: McKinney (2013)

DataFrame representa uma tabela, uma estrutura de dados do tipo planilha, que possui uma coleção ordenada de colunas, onde cada uma delas pode ter um tipo de valor diferente (numérico, *string*, *boolean*, etc.). O *DataFrame* possui um índice para linhas e também para colunas. Pode ser interpretado como um dicionário de *Series*. De uma maneira geral, o dado é armazenado como um ou mais blocos bi-dimensionais ao invés de uma lista, dicionário, ou outro tipo de coleção de matriz unidimensional (MCKINNEY, 2013).

Existem várias maneiras diferentes de se criar um *DataFrame*, entretanto uma forma comum é um dicionário de dimensões iguais, conforme a Figura 3 e a Figura 4, ou uma matriz *NumPy*.

```
data = {'state': ['Ohio', 'Ohio', 'Ohio', 'Nevada', 'Nevada'],
        'year': [2000, 2001, 2002, 2001, 2002],
        'pop': [1.5, 1.7, 3.6, 2.4, 2.9]}

frame = DataFrame(data)
```

FIGURA 3: Criação de um *DataFrame*

FONTE: McKinney (2013)

```
[In [9]: frame
Out[9]:
```

	pop	state	year
0	1.5	Ohio	2000
1	1.7	Ohio	2001
2	3.6	Ohio	2002
3	2.4	Nevada	2001
4	2.9	Nevada	2002

FIGURA 4: Conteúdo de um *DataFrame* pelo interpretador *IPython*

FONTE: McKinney (2013)

4.1.1.3 Biblioteca *matplotlib*

O pacote *matplotlib* é desenvolvido para a geração de gráficos bidimensionais a partir de *arrays*. Gráficos comuns podem ser criados com alta qualidade a partir de simples comandos, inspirados nos comandos gráficos do MATLAB, exemplo ilustrado na Figura 5.

Quando usado em conjunto com ferramentas GUI (*IPython*, por exemplo), esta biblioteca possui recursos interativos como zoom e visão panorâmica. Além disto, suporta várias ferramentas GUI *backend*, nos diversos sistemas operacionais suporta-

dos pelo Python, e permitem exportar gráficos em diversos formatos: PDF, SVG, JPG, PNG, BMP, GIF, etc.

matplotlib também possui várias ferramentas adicionais, como o *mplot3d* para plotar gráficos tridimensionais, e o *basemap* para mapeamentos e projeções.




FIGURA 5: Exemplo de um gráfico gerado pelo *matplotlib*

FONTE: Wiener (2014)

4.1.1.4 Biblioteca *SciPy*

SciPy é uma coleção de pacotes que abordam uma série de soluções para diferentes domínios na computação científica. Na lista a seguir são apresentados exemplos desses pacotes (MCKINNEY, 2013):

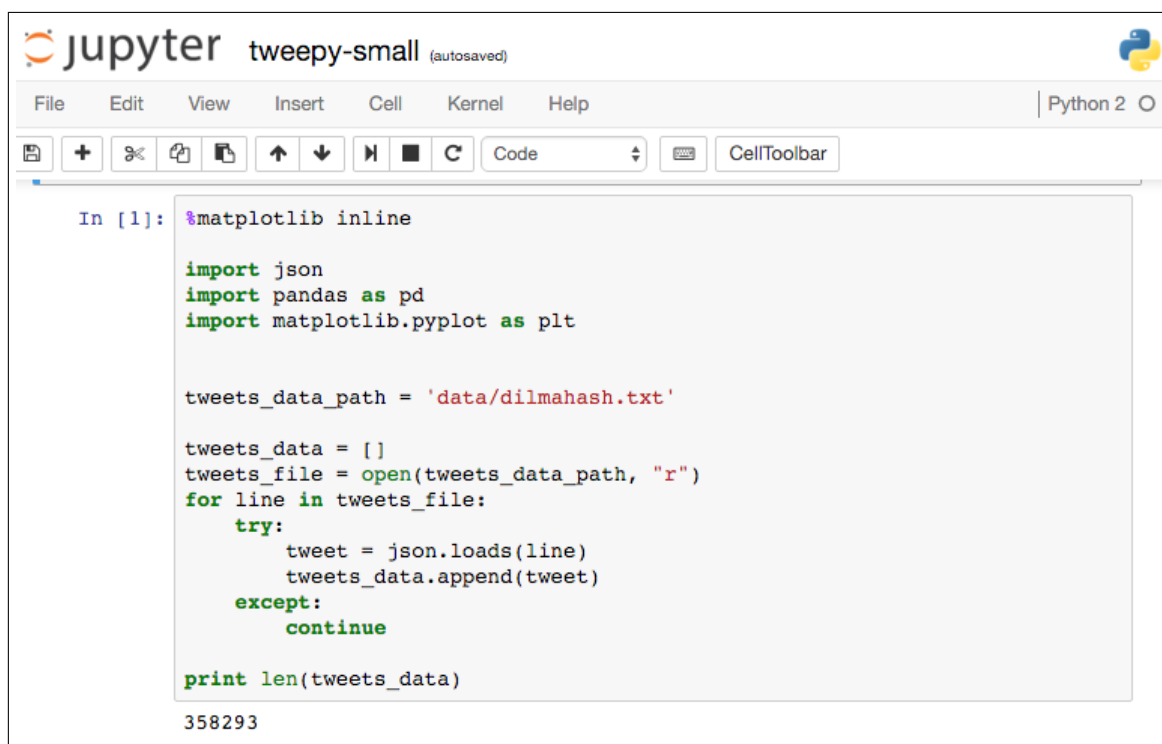
- *scipy.integrate*: rotinas de integração numéricas e soluções de equações diferenciais;
- *scipy.linalg*: rotinas de álgebra linear e decomposição de matrizes;
- *scipy.optimize*: funções otimizadoras (minimizadoras) e algoritmos de busca em raiz;

- *scipy.signal*: ferramentas para processamento de sinais;
- *scipy.sparse*: matrizes esparsas e soluções de sistemas lineares esparsos;
- *scipy.special*: agregador do *SPECFUN*, uma biblioteca do Fortran que implementa várias funções matemáticas, como exemplo, a função gama;
- *scipy.stats*: funções estatísticas, variáveis contínuas e discretas, testes estatísticos e outros modelos estatísticos;
- *scipy.weave*: ferramenta para usar códigos *inline* de C++ para acelerar a computação de matrizes.

4.1.1.5 Interpretador *IPython*

O interpretador *IPython* teve seu desenvolvimento iniciado em 2001, com o intuito de ser um interpretador interativo para a linguagem Python. Desde a sua criação o *IPython* evoluiu grandemente, ao ponto de ser considerada uma das mais importantes ferramentas para computação científica em Python. Essa biblioteca não oferece nenhuma ferramenta para análise de dados ou análise computacional em si, sendo designada para maximizar a produtividade, tanto na interação computacional como no desenvolvimento de softwares. Oferece um fluxo de visualização de um modo *execute-explore* ao invés do típico modelo *edit-compile-run* de muitas outras linguagens de programação. Ela também provê uma pequena integração com o *shell* e sistemas de arquivos. Como a maior parte da programação focada na mineração de dados envolve exploração, tentativa, erro e iteração, *IPython*, em quase todos os casos, irá facilitar este tipo de trabalho (MCKINNEY, 2013).

Hoje, o projeto *IPython*, mantido pela empresa *Jupyter*, engloba muito mais do que apenas um interpretador *shell* para Python. Ele também inclui um console gráfico interativo, o *IPython Notebook*, que provê ao usuário uma experiência de caderno (*notebook-like*) através de um navegador *web*, conforme Figura 6, e dispõe de um mecanismo de processamento paralelo. Assim como muitas outras ferramentas desenvolvidas para programadores, é extremamente customizável (RUSSELL, 2013).



The image shows a Jupyter Notebook window titled "tweepy-small (autosaved)". The interface includes a menu bar (File, Edit, View, Insert, Cell, Kernel, Help) and a toolbar with icons for file operations and execution. The code cell contains the following Python code:

```
In [1]: %matplotlib inline

import json
import pandas as pd
import matplotlib.pyplot as plt

tweets_data_path = 'data/dilmahash.txt'

tweets_data = []
tweets_file = open(tweets_data_path, "r")
for line in tweets_file:
    try:
        tweet = json.loads(line)
        tweets_data.append(tweet)
    except:
        continue

print len(tweets_data)
```

The output of the code cell is the number 358293.

FIGURA 6: Exemplo de uma página web do *IPython Notebook*

FONTE: Elaborado pelo autor

4.1.2 Interface de Programação de Aplicações - API

API é uma sigla para *Application Programming Interface* e basicamente é uma tecnologia que permite um pedaço de *software* se comunicar com outro pedaço de *software*. Existem vários tipos de API e é comumente referenciado a outras tecnologias. Por exemplo, para o desenvolvimento deste trabalho será utilizado a API do *Twitter*.

Uma API é composta por uma série de funções acessíveis somente por programação, e que permitem utilizar características do *software* menos evidentes ao utilizador tradicional.

4.1.2.1 Arquitetura REST

Abreviação para Transferência de Estado Representacional (REST), é um estilo arquitetural baseado em recursos e nas representações desses recursos. Enfatiza a escalabilidade na interação entre componentes, a generalidade de interfaces, a implantação independente dos componentes de um sistema, o uso de componentes intermediários visando a redução na latência de interações, o reforço na segurança e o encapsulamento de sistemas legados. A REST ignora os detalhes da implementação de componente e a sintaxe de protocolo com o objetivo de focar nos papéis dos componentes, nas restrições sobre sua interação com outros componentes e na sua

interpretação de elementos de dados significantes (FIELDING, 2000).

REST foi um termo criado por Fielding (2000), onde ele modela um estilo de arquitetura para a construção de serviços *web* consistentes e coesos. O estilo da arquitetura REST é baseado em recursos e nos estados desses recursos.

A funcionalidade de uma REST API é similar ao funcionamento de uma página *web*, onde o usuário efetua uma requisição a um servidor *web*, utilizando o protocolo HTTP, e recebe dados como resposta.

Um recurso é qualquer conteúdo ou informação que é exposto na Internet, podendo ser um documento, vídeo clip, até processos de negócio ou dispositivos. Para utilizar um recurso é necessário ser capaz de identificá-lo na rede e de ter meios para manipulá-lo. Tem-se então, o *Uniform Resource Identifiers* (URI) para este propósito. Um URI unicamente identifica um recurso e, ao mesmo tempo, o torna endereçável ou capaz de ser manipulado utilizando um protocolo, como o HTTP. O URI de um recurso se distingue dos de qualquer outro recurso e é através do próprio URI que ocorrem as interações com o recurso (WEBBER; PARASTATIDIS; ROBINSON, 2010).

Recursos devem possuir pelo menos um identificador para ser endereçável, e cada identificador é associado com uma ou mais representações, que é uma transformação ou uma visão do estado do recurso em um instante de tempo. Essa visão é codificada em um ou mais formatos transferíveis, tal como XHTML, Atom, texto simples, XML, YML, JSON, JPG, MP3, entre outros (WEBBER; PARASTATIDIS; ROBINSON, 2010).

Os recursos provêm o conteúdo ou objeto com o qual se quer interagir e para atuar sobre eles é utilizado os métodos de HTTP. Os métodos HTTP na arquitetura REST podem ser referenciados como Verbos, uma vez que representam ações sobre os recursos (WEBBER; PARASTATIDIS; ROBINSON, 2010).

4.1.3 Protocolo de Autenticação - OAuth

Protocolos de autenticação são capazes de, simplesmente, autenticar a parte que está se conectando, ou ainda de autenticar a parte que está conectando, assim como se autenticar para ele.

Neste trabalho será utilizado apenas o protocolo OAuth 1.0 para o acesso aos dados do *Twitter*. É possível também, realizar a autenticação utilizando a versão mais atual, OAuth 2.0, mas será apenas referenciado, neste trabalho, para a melhor compreensão do funcionamento do protocolo.

OAuth é uma sigla para "*open authorization*", ou autorização aberta, e provê um meio para que usuários autorizem uma aplicação acessar dados, com alguma finalidade, através de uma API, sem que os usuários precisem passar credenciais

como nome de usuário e senha. De um modo geral, usuários são capazes de controlar o nível de acesso para estas aplicações e revogar este controle a qualquer momento (RUSSELL, 2013).

4.1.3.1 Protocolo OAuth 1.0a

OAuth 1.0a é um protocolo que permite que um cliente (*client*) *web* tenha acesso a um recurso protegido pelo seu dono em um servidor. Esta definição se dá através da RFC 5849. Que são documentos técnicos desenvolvidos e mantidos pelo Internet Engineering Task Force (IETF), instituição que especifica os padrões que serão implementados e utilizados em toda a Internet.

A razão para a existência dessa tecnologia é para evitar problemas de usuários (donos dos recursos) compartilhar suas senhas com aplicações *web*.

A versão OAuth 1.0a não permite que credenciais sejam trocadas utilizando uma conexão *Secure Socket Layer* (SSL) através de um protocolo HTTPS. Por esse motivo, muitos desenvolvedores achavam tedioso o trabalho devido aos vários detalhes envolvidos em encriptação.

SSL é um padrão global para tecnologia de segurança. Tem como função principal criar um canal criptografado entre um servidor *web* e um navegador (*browser*) para garantir que todos os dados transmitidos sejam seguros e sigilosos.

Uma aplicação que está requerindo acesso é conhecida como *client*, em alguns momentos chamado de *consumer*, a rede social ou o serviço que contém os recursos protegidos é nomeado como *server* (também chamado de *provider*) e o usuário que concede o acesso é o *resource owner* (dono do recurso, tradução livre). Com estes elementos, as três participações que envolvem o processo e a interação que estes elementos possuem é conhecida como "*three-legged-flow*" ou de uma maneira mais coloquial, a *OAuth dance*. Estas são as etapas fundamentais que envolvem a *OAuth dance* que, como resultado, permite ao *client* o acesso a recursos protegidos, conforme listado a seguir (RUSSELL, 2013):

1. O *client* obtém um *token* de requisição do servidor de serviço (aplicação);
2. O dono do recurso autoriza o *token* de requisição;
3. O *client* troca o *token* de requisição por um *token* de acesso;
4. O *client* usa o *token* de acesso para acessar os recursos protegidos com a consideração do dono do recurso.

Para credenciais particulares, um *client* começa com uma *consumer key* e um *consumer secret* e no fim do processo de *OAuth dance*, termina com um *token* de

acesso e *token* de acesso secreto que pode ser usado para acessar recursos protegidos.

4.1.3.2 Protocolo OAuth 2.0

Enquanto o protocolo OAuth 1.0a permite uma autorização útil para o acesso a aplicações *web*, o OAuth 2.0 foi originalmente destinado a simplificar, significativamente, a implementação detalhada para desenvolvedores de aplicações *web*, baseando-se completamente no SSL para aspectos de segurança e para satisfazer uma vasta quantidade de casos de uso. Esses casos de uso variaram desde suporte para dispositivos móveis à necessidades empresariais e, conseqüentemente, às necessidades de um termo mais futuro, da "Internet das Coisas" (RUSSELL, 2013).

Diferentemente da implementação OAuth 1.0a, que consiste de um rígido conjunto de etapas, a implementação do OAuth 2.0, definido através do RFC 6749, pode variar de acordo com a particularidade do caso de uso. Um decorrer típico da execução do OAuth 2.0 tem a vantagem do SSL e, essencialmente, contém apenas poucos redirecionamentos que, acompanhada de um alto-nível, não possui tanta diferença em relação ao processo anterior que envolvem um ciclo do OAuth 1.0a.

4.1.4 Rede Social *Twitter*

Para definir o que seria o *Twitter*, Russell (2013) aborda as seguintes necessidades que uma tecnologia social precisa disponibilizar à uma pessoa:

- Permitir que a pessoa seja ouvida;
- Permitir que a pessoa satisfaça suas curiosidades;
- Permitir isso de um modo fácil e acessível;
- Permitir isso agora.

Essas observações são, de um modo geral, verdadeiramente humano. Pessoas possuem o desejo de compartilhar ideias e experiências, que as permitam se conectarem com outras pessoas, para serem ouvidas, e se sentirem parte ou digna de importância (HUBERMAN; ROMERO; WU, 2008).

Os dois últimos itens enfatizam a vontade de não ter alguma dificuldade para satisfazer as curiosidades ou realizar algum trabalho específico (RUSSELL, 2013).

Uma maneira de descrever o *Twitter* é, então, um serviço de *microblog* que permite uma breve comunicação entre pessoas. Mensagens de no máximo 140 caracteres explicam a "breve comunicação", que normalmente correspondem a pensamentos

ou ideias sobre um determinado assunto. Em outras palavras, *Twitter* é um serviço global de trocas de mensagens, extremamente rápido e gratuito (KWAK et al., 2010).

Outro elemento interessante para a utilização dessa rede social é a assimetria ao "seguir" uma pessoa. Esta liberdade permite aos usuários atender as suas curiosidades. Diferentemente de outras redes sociais, como *Facebook* e *LinkedIn*, que requer uma aceitação mútua da conexão entre os usuários, o modelo de relacionamento no *Twitter* viabiliza os acontecimentos de qualquer outro cliente na rede. Podendo ser alguma especulação sobre celebridades, atualizações sobre times de esportes, algum tópico particular político, ou o simples desejo de se conectar a alguém (HUBERMAN; ROMERO; WU, 2008).


4.1.4.1 API do *Twitter*

Twitter é caracterizado como um serviço de *microblog* em tempo real, que permite os usuários postarem pequenas atualizações de qualquer situação que desejar, essas postagens são chamados de *tweets*, que aparecem em *timelines* (linhas de tempo). *Tweets* podem incluir uma ou mais entidades em seus 140 caracteres de conteúdo e referenciar um ou mais lugares que mapeiam localizações do mundo real (RUSSELL, 2013).

É necessário ter um entendimento sobre usuários (*users*), *tweets* e *timelines* para o uso efetivo da API do *Twitter*. Será, então, abordado uma breve explicação sobre a plataforma de objetos do *Twitter*, com o intuito de interagir com a sua API para a coleta de dados (TWITTER, 2016b).

Tweets são a essência do *Twitter*, e apesar deles serem representados como 140 caracteres de conteúdo textual associado a uma atualização de um usuário, existe muito mais informação através dos metadados. Em adição ao conteúdo textual de um *tweet*, eles vem empacotados em dois pedaços de metadados: entidades e lugares. Entidades de um *tweet* são basicamente menções de usuários, *hashtags*, URLs, e mídias que são associadas a um *tweet*. E lugares são localizações no mundo real que podem estar adjunto a um *tweet*. Um lugar pode ser uma localização atual aonde o *tweet* foi composto, mas também pode ser uma referência a algum lugar descrito no *tweet* (TWITTER, 2016b).

Para exemplificar, considere o *tweet* apresentado pela Figura 7. O *tweet* possui 83 caracteres (incluindo espaços e quebra de linhas) e contem quatro entidades: duas *hashtags* #GameOfThrones e #Linux, uma menção ao usuário @itsfoss e uma imagem como conteúdo de mídia. Não existe porém, uma localidade exposta nesta postagem. Porém existe muito mais informações no metadado deste *tweet* que demonstra a quantidade de dados que se pode coletar.

FIGURA 7: Exemplo de um *tweet*

FONTE: Twitter (2016a)

Por fim, *timelines* são coleções de *tweets* ordenadas cronologicamente. É possível afirmar, que *timeline* é qualquer coleção específica de *tweets* apresentadas em uma ordem cronológica. Através da perspectiva de um usuário do *Twitter*, a *timeline* inicial (*home*) é a visualização principal quando este usuário acessa a sua conta no serviço do *Twitter* (RUSSELL, 2013).

Quando este acesso é realizado, normalmente, acontece através do endereço <https://twitter.com>. A URL para a *timeline* de algum usuário em particular, no entanto, precisa ser sufixado com o contexto que identifica este usuário específico, por exemplo <https://twitter.com/unixstickers>.

Uma aplicação como o *TweetDeck* disponibiliza a customização da visualização de várias *timelines*, como demonstra a Figura 8.

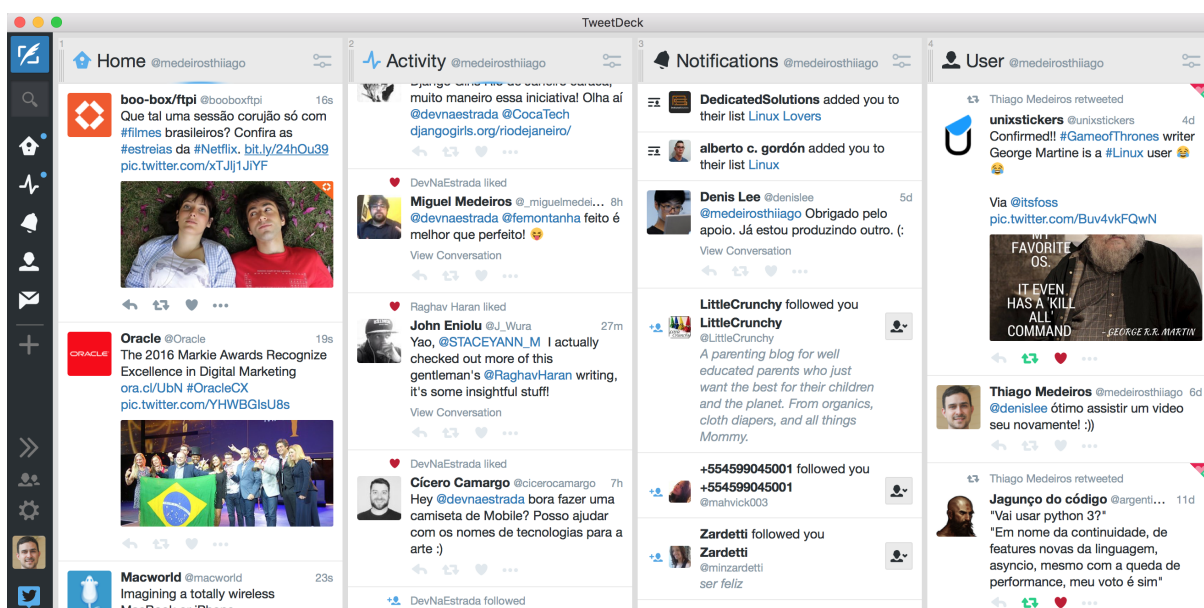


FIGURA 8: Aplicação *TweetDeck* apresentando várias *timelines*

FONTE: Elaborado pelo autor

Enquanto *timelines* são coleções de *tweets* com uma velocidade relativamente baixa de atualizações, *streams* são amostras de *tweets* públicos fluindo através do *Twitter* em tempo real. Uma ferramenta pública que a rede social disponibiliza é o *firehose*, que permite coletar, ou visualizar, centenas de milhares de *tweets* por minuto durante eventos com interesses bem abrangentes, como debates presidenciais, finais de campeonatos esportivos e outros acontecimentos que engloba milhares de internautas (TWITTER, 2016b).

4.1.4.2 Bibliotecas Para o Consumo de Dados da API do *Twitter*

O acesso a API acontece através da criação de uma aplicação pela página *web* de desenvolvimento do *Twitter*, <https://apps.twitter.com>. Após a criação desta aplicação é fornecido ao usuário informações para o acesso utilizando o protocolo OAuth. Será informado uma chave exclusiva da API da aplicação, uma chave secreta, o *token* de usuário OAuth e credenciais secretas do usuário OAuth (RUSSELL, 2013).

Com estas credencias é possível, então, ter acesso a API do *Twitter* e, consequentemente, o que a mesma disponibiliza para os usuários. Para o consumo desta

API, a linguagem de programação Python apresenta algumas bibliotecas que facilita este tipo de serviço, listadas a seguir:

- *requests-oauthlib*;
- *tweepy*;
- *python-twitter*;
- *oauthlib*.

A biblioteca *tweepy*, será a mais utilizada para as implementações deste trabalho devido a fácil interação com a API do *Twitter*. Esta biblioteca permite o acesso a todos os métodos presentes na API, cada método pode aceitar parâmetros diversos e retornar respostas quando invocados (TWEETPY, 2009).

O Código 1 exemplifica o consumo da API segundo Tweepy (2009).

```
1 import tweepy
2
3 auth = tweepy.OAuthHandler(consumer_key, consumer_secret)
4 auth.set_access_token(access_token, access_token_secret)
5
6 api = tweepy.API(auth)
7
8 public_tweets = api.home_timeline()
9 for tweet in public_tweets:
10     print tweet.text
```

CÓDIGO 1: Acesso à API do *Twitter*

Quando um método da API é invocado, quase todos os seus retornos será uma instância de um modelo *tweepy*. Este modelo irá conter dados retornados do *Twitter* onde é possível manipulá-los da maneira como o programador preferir (TWEETPY, 2009).

4.2 METODOLOGIA E DESENVOLVIMENTO

4.2.1 Iterativo e Incremental

5 IMPLEMENTAÇÃO DAS TÉCNICAS E ANÁLISE DOS RESULTADOS

Este capítulo tem como finalidade apresentar com um maior nível de detalhamento as técnicas utilizadas neste trabalho, com o objetivo de se atingir as metas propostas já descritas no Capítulo 1, na seção 1.2.

5.1 COLETA DE DADOS

Uma característica comentada anteriormente sobre a rede social *Twitter* é a disponibilidade de informações de eventos em tempo real. Os *tweets* podem ser postados com o intuito de comentar sobre a final de um campeonato de futebol, datas importantes, acontecimentos internacionais e políticos, entre outros.

Para este trabalho foi aproveitado o dia 17 de abril de 2016, onde foi realizado a votação do Congresso Brasileiro pela continuação do processo de Impeachment do cargo de presidente da senhora Dilma Rouseff. Neste dia milhares de *tweets* foram publicados utilizando a *hashtag* #ImpeachmentDay com o objetivo de comentar sobre o evento de votação e, também, a atual situação política do Brasil.

Com a finalidade de coletar todos os dados da referida *hashtag*, foi desenvolvido um *script* que utiliza o serviço de *Stream* do *Twitter*, também conhecido como *FireHose*.

As primeiras linhas do Código 2 servem para importar as bibliotecas e objetos necessários para a utilização da API do *Twitter*, assim como as informações das chaves de acesso e *tokens* para o protocolo OAuth, que são fundamentais para a comunicação com o serviço de *Stream*.

```

1 from tweepy.streaming import StreamListener
2 from tweepy import OAuthHandler
3 from tweepy import Stream
4
5 access_token = "131556934-LrYRiXzAL3QcRyFN0fdN53EDWhNGfZFnVX59NCnT"
6 access_token_secret = "JraMtps5IB98d8XoelAF71KHn8ZQ4nshdoSKiFITz6OHd"
7 consumer_key = "P4XZ2GUkeqdhIIQMoredBuW05"
8 consumer_secret = "r5TPb2UcM8bzxq7t5zflRPMHUrCfwNG4GRuVPXypowrpHhTmue"
9
10
11 class StdOutListener(StreamListener):
12
13     def on_data(self, data):
14         print data
15         return True
16

```

```

17     def on_error(self, status):
18         print status
19
20
21 if __name__ == '__main__':
22
23     l = StdOutListener()
24     auth = OAuthHandler(consumer_key, consumer_secret)
25     auth.set_access_token(access_token, access_token_secret)
26     stream = Stream(auth, l)
27
28     stream.filter(track=['ImpeachmentDay', 'NaoVaiTerGolpe', 'ForaDilma'↵
    ])

```

CÓDIGO 2: *Script coletar-hashtags.py*

A partir da linha 11 é criado uma classe que instancia um serviço de escuta para este *Stream*. O serviço de escuta é responsável por observar todos os *tweets* que são publicados e após identificar no *tweet* alguma palavra ou a *hashtag* semelhante a palavra declarada na linha 28, é então capturado e impresso na tela de execução do *script*.

Quando este *script* está em execução é mostrado na tela todos os *tweets* que estão sendo coletados, já filtrados, porém não está sendo persistido em nenhum arquivo ou banco de dados. Com o intuito de salvar todos estes dados foi utilizado o comando *stdout* (>), presente em sistemas operacionais de base *Unix*. O comando *stdout* permite redirecionar a saída do código anterior, no caso a execução do *script* coletar-hashtags.py, para um novo arquivo ou um arquivo já existente conforme ilustrado pela Figura 9.

```

scripts git:(master) x
> python coletar-hashtags.py > ../data/coleta-impeachment.json

```

FIGURA 9: Execução do *script* para coleta de dados

FONTE: Elaborado pelo autor

O *script* apresentado no Código 2 permaneceu em execução durante 14 horas (das 08:30 às 22:30) do dia 17 de abril, concluindo em um arquivo de 2.6 gigabytes. O formato deste arquivo é um JSON onde apresenta todas as informações presentes em um *tweet*, demonstrado através do Código 3.

```

1 {
2     "created_at": "Sun Apr 17 15:15:21 +0000 2016",
3     "id": 721718699418202112,
4     "id_str": "721718699418202112",

```



```

5   "text": "RT @GarotaCiume: N\u00e3o sou petista , s\u00f3 n\u00e3o sou ↵
    cega. Impeachment sem crime de responsabilidade \u00e9 golpe , e voc\↵
    u00eas est\u00e3o traindo a democracia. #\u2026",
6   "source": "\u003ca href=\"http://\twitter.com/download/android\" ↵
    rel=\"nofollow\"\u003eTwitter for Android\u003c/a\u003e",
7   "truncated": false ,
8   "in_reply_to_status_id": null ,
9   "in_reply_to_status_id_str": null ,
10  "in_reply_to_user_id": null ,
11  "in_reply_to_user_id_str": null ,
12  "in_reply_to_screen_name": null ,
13  "user": {
14      "id": 1876843824,
15      "id_str": "1876843824",
16      "name": "Millena Souza",
17      "screen_name": "Souzaa_mih1",
18      "location": "Brasil , Vit\u00f3ria – ES",
19      "url": "https://\www.facebook.com/myllena.souzaa",
20      "description": "Brasileira 15 , paulista e capixaba, feminista ,↵
    Taurina e n\u00e3o sou obrigada a nada \u2764\u2764 BORN TO DIE !!",
21      "protected": false ,
22      "verified": false ,
23      "followers_count": 433,
24      "friends_count": 431,
25      "listed_count": 0,
26      "favourites_count": 613,
27      "statuses_count": 28370,
28      "created_at": "Tue Sep 17 20:52:04 +0000 2013",
29      "utc_offset": -10800,
30      "time_zone": "Brasilia",
31      "geo_enabled": true ,
32      "lang": "pt",
33      "contributors_enabled": false ,
34      "is_translator": false ,
35      "profile_background_color": "611994",
36      "profile_background_image_url": "http://\pbs.twimg.com/\↵
    profile_background_images/378800000076733988/60↵
    df12d5296d8d8081e19c306c15c859.jpeg",
37      "profile_background_image_url_https": "https://\pbs.twimg.com/\↵
    profile_background_images/378800000076733988/60↵
    df12d5296d8d8081e19c306c15c859.jpeg",
38      "profile_background_tile": true ,
39      "profile_link_color": "6B25C7",
40      "profile_sidebar_border_color": "FFFFFF",
41      "profile_sidebar_fill_color": "7AC3EE",
42      "profile_text_color": "3D1957",
43      "profile_use_background_image": true ,

```

```

44     "profile_image_url": "http://pbs.twimg.com/profile_images↵
    \699081483546443776\uCBDXAfO_normal.jpg",
45     "profile_image_url_https": "https://pbs.twimg.com/↵
    profile_images\699081483546443776\uCBDXAfO_normal.jpg",
46     "profile_banner_url": "https://pbs.twimg.com/profile_banners↵
    \1876843824\1455509034",
47     "default_profile": false,
48     "default_profile_image": false,
49     "following": null,
50     "follow_request_sent": null,
51     "notifications": null
52 },
53 "geo": null,
54 "coordinates": null,
55 "place": null,
56 "contributors": null,
57 "retweeted_status": {
58     "created_at": "Sun Apr 17 15:07:13 +0000 2016",
59     "id": 721716654569349121,
60     "id_str": "721716654569349121",
61     "text": "N\u00e3o sou petista, s\u00f3 n\u00e3o sou cega. ↵
    Impeachment sem crime de responsabilidade \u00e9 golpe, e voc\u00eas ↵
    est\u00e3o traindo a democracia. #ImpeachmentDay",
62     "source": "\u003ca href=\"http://twitter.com/download/iphone↵
    \" rel=\"nofollow\"\u003eTwitter for iPhone\u003c/a\u003e",
63     "truncated": false,
64     "in_reply_to_status_id": null,
65     "in_reply_to_status_id_str": null,
66     "in_reply_to_user_id": null,
67     "in_reply_to_user_id_str": null,
68     "in_reply_to_screen_name": null,
69     "user": {
70         "id": 206181302,
71         "id_str": "206181302",
72         "name": "Garota Ci\u00fame",
73         "screen_name": "GarotaCiume",
74         "location": "snapchat \u2728 leuncosta \u2728",
75         "url": "http://Instagram.com/leuncosta",
76         "description": "Ciume \u00e9 igual bater o dedinho do p\u00e9↵
    no sof\u00e1: coisa boba, mas d\u00f3i demais. \u2022 contato: ↵
    contatogarotaciume@gmail.com",
77         "protected": false,
78         "verified": false,
79         "followers_count": 1202807,
80         "friends_count": 139,
81         "listed_count": 383,
82         "favourites_count": 40277,

```

```

83         "statuses_count": 25882,
84         "created_at": "Fri Oct 22 12:52:10 +0000 2010",
85         "utc_offset": -10800,
86         "time_zone": "Brasilia",
87         "geo_enabled": true,
88         "lang": "pt",
89         "contributors_enabled": false,
90         "is_translator": false,
91         "profile_background_color": "FFFFFF",
92         "profile_background_image_url": "http://pbs.twimg.com/profile_background_images/879103282/2454b176f3fffc4b100fb2bc64b1f2b5.png",
93         "profile_background_image_url_https": "https://pbs.twimg.com/profile_background_images/879103282/2454b176f3fffc4b100fb2bc64b1f2b5.png",
94         "profile_background_tile": false,
95         "profile_link_color": "383838",
96         "profile_sidebar_border_color": "FFFFFF",
97         "profile_sidebar_fill_color": "F6F6F6",
98         "profile_text_color": "000000",
99         "profile_use_background_image": true,
100        "profile_image_url": "http://pbs.twimg.com/profile_images/3719404815/b868778f39b4b087561e3444b3093e20_normal.gif",
101        "profile_image_url_https": "https://pbs.twimg.com/profile_images/3719404815/b868778f39b4b087561e3444b3093e20_normal.gif",
102        "profile_banner_url": "https://pbs.twimg.com/profile_banners/206181302/1403658723",
103        "default_profile": false,
104        "default_profile_image": false,
105        "following": null,
106        "follow_request_sent": null,
107        "notifications": null
108    },
109    "geo": null,
110    "coordinates": null,
111    "place": null,
112    "contributors": null,
113    "is_quote_status": false,
114    "retweet_count": 153,
115    "favorite_count": 130,
116    "entities": {
117        "hashtags": [{
118            "text": "ImpeachmentDay",
119            "indices": [121, 136]
120        }],
121        "urls": [],

```

```
122         "user_mentions": [],
123         "symbols": []
124     },
125     "favorited": false,
126     "retweeted": false,
127     "filter_level": "low",
128     "lang": "pt"
129 },
130 "is_quote_status": false,
131 "retweet_count": 0,
132 "favorite_count": 0,
133 "entities": {
134     "hashtags": [{
135         "text": "ImpeachmentDay",
136         "indices": [139, 140]
137     }],
138     "urls": [],
139     "user_mentions": [{
140         "screen_name": "GarotaCiume",
141         "name": "Garota Ci\u00fame",
142         "id": 206181302,
143         "id_str": "206181302",
144         "indices": [3, 15]
145     }],
146     "symbols": []
147 },
148 "favorited": false,
149 "retweeted": false,
150 "filter_level": "low",
151 "lang": "pt",
152 "timestamp_ms": "1460906121483"
153 }
```

CÓDIGO 3: Exemplo de um *tweet* no formato JSON

5.2 ANÁLISE DE DADOS

Após a coleta de dados foi gerado, então, um arquivo JSON de 2.6 gigabytes. Portanto a próxima etapa será analisar estes dados para extrair informações úteis.

Foi realizado testes no arquivo JSON coletado para verificar se existe algum tipo de *dirty data*, que são informações quebradas, dados irrelevantes ou códigos que impedem a execução de *scripts* de mineração (PIPINO; KOPCSO, 2004). A Figura 10 demonstra o único padrão de *dirty data* encontrado dentro do arquivo.

Dentro das milhares linhas do arquivo, existem algumas linhas contendo este mesmo padrão ("limit:"), que foram removidos utilizando outra ferramenta de sistemas

```
{"created_at":"Mon Apr 18 02:46:16 +0000 2016","id":721892}
{"created_at":"Mon Apr 18 02:46:16 +0000 2016","id":721892}
{"created_at":"Mon Apr 18 02:46:17 +0000 2016","id":721892}
{"limit":{"track":11138,"timestamp_ms":"1460947577319"}}
{"created_at":"Mon Apr 18 02:46:17 +0000 2016","id":721892}
{"created_at":"Mon Apr 18 02:46:17 +0000 2016","id":721892}
{"created_at":"Mon Apr 18 02:46:17 +0000 2016","id":721892}
```

FIGURA 10: *Dirty Data* presente no arquivo coletado

FONTE: Elaborado pelo autor

baseados em Unix, o *grep*.

A ferramenta *grep* é considerada um "canivete suíço" para o uso de expressões regulares e possui uma funcionalidade que permite realizar uma consulta inversa, ou seja, o usuário passa um padrão ou uma palavra que se deseja encontrar dentro de um determinado arquivo, e após encontrar todas as ocorrências, o *grep* seleciona tudo o que não contém este padrão ou palavra.

Combinado com o comando de *stdout* (>), é possível redirecionar todos os dados que não possui este tipo de *dirty data* para um novo arquivo conforme a Figura 11.

```
data git:(master) x
> grep --invert-match '{"limit":' coleta-impeachment.json > coleta-sem-dirty-data.json
```

FIGURA 11: Utilizando o comando *grep* para gerar um novo arquivo sem *dirty data*

FONTE: Elaborado pelo autor

Tendo então um arquivo JSON sem a presença de *dirty data* é possível iniciar o processo de extração de conhecimento utilizando o interpretador *IPython*.

Nesta primeira etapa é importado as bibliotecas necessárias para se trabalhar com arquivos do tipo JSON e também para a geração de gráficos, conforme o Código 4.

```
1 %matplotlib inline
2
3 import json
4 import pandas as pd
5 import matplotlib.pyplot as plt
6
7
8 tweets_data_path = 'data/coleta-sem-dirty-data.json'
9
10 tweets_data = []
11 tweets_file = open(tweets_data_path, "r")
12 for line in tweets_file:
13     try:
14         tweet = json.loads(line)
15         tweets_data.append(tweet)
16     except:
17         continue
18
19 tweets = pd.DataFrame()
20 print len(tweets_data)
```

CÓDIGO 4: Leitura do arquivo JSON

A primeira linha do Código 4 permite a visualização de gráficos e planilhas no *IPython*. A partir da linha 8, é realizado a construção de um *DataFrame*, que é definido na seção 4.1.1.2, através leitura do arquivo coleta-sem-dirty-data.json.


A execução deste código permite, então, gerar um *DataFrame* e informar o número de *tweets* que ele contém. Esses *DataFrames* possuem uma arquitetura semelhante ao formato de tabelas em que é possível adicionar uma coluna ou uma tabela a uma variável em Python. Através do mapeamento de uma condição específica em um *DataFrame*, apresentado no Código 5 para mapear o texto, a língua e o país em que o *tweet* foi publicado.

```
1 tweets['text'] = map(lambda tweet: tweet['text'], tweets_data)
2 tweets['lang'] = map(lambda tweet: tweet['lang'], tweets_data)
3 tweets['country'] = map(lambda tweet: tweet['place']['country']
4                          if tweet['place'] != None else None, tweets_data)
5
6 tweets_by_lang = tweets['lang'].value_counts()
7
8 fig, ax = plt.subplots(figsize=(20,10))
9 ax.tick_params(axis='x', labelsz=20)
10 ax.tick_params(axis='y', labelsz=15)
11 ax.set_xlabel('Linguas'.decode('utf-8'), fontsize=20)
12 ax.set_ylabel('Numero de tweets'.decode('utf-8'), fontsize=20)
13 ax.set_title('Top 4 Linguas'.decode('utf-8'),
14             fontsize=20, fontweight='bold')
```

```
15 tweets_by_lang[:4].plot(ax=ax, kind='bar', color='mediumspringgreen')
16 plt.grid()
```

CÓDIGO 5: Mapeamento de variáveis para um *DataFrame*

Após o mapeamento das informações do *DataFrame* foi construído um gráfico em barras que indica as quantidades de *tweets* em relação as quatro línguas mais significativas no conjunto de dados coletados. A Figura 12 apresenta o gráfico gerado.

FIGURA 12: Línguas que mais realizaram *tweets*

FONTE: Elaborado pelo autor

É possível verificar nesta figura que existe uma barra com o nome de *und* para especificar a segunda língua que realizou mais *tweets*. Essa é uma condição em que não foi identificada a língua de origem e então a API do *Twitter* classifica como *undefined*, ou indefinido no português. Essa linguagem indefinida ocorre devido ao *software* em que o usuário está realizando o *tweet*, por exemplo um navegador *web*, um aplicativo *mobile* do *Twitter* ou algum aplicativo de terceiro que permite realizar ações no *Twitter*. Caso a linguagem não esteja definida nestes ambientes a API a classifica como indefinida.


Semelhante ao Código 5 é possível verificar quais os países que estão comentando sobre a *hashtag* *#ImpeachmentDay* através do Código 6.

```
1 tweets_by_country = tweets['country'].value_counts()
2
3 fig, ax = plt.subplots(figsize=(20,10))
4 ax.tick_params(axis='x', labelsiz=15)
5 ax.tick_params(axis='y', labelsiz=15)
```

```
6 ax.set_xlabel('Países'.decode('utf-8'), fontsize=20)
7 ax.set_ylabel('Número de tweets'.decode('utf-8'), fontsize=20)
8 ax.set_title('Top 5 Países'.decode('utf-8'), fontsize=20, fontweight='↵
  bold')
9 tweets_by_country[:5].plot(ax=ax, kind='bar', color='lightskyblue')
10 plt.grid()
```

CÓDIGO 6: Contabilização do número de *tweets* por países

O Código 6 verifica quais são os cinco países que mais realizaram *tweets* através do mapeamento do *DataFrame* e então constrói o gráfico em barras representado pela Figura 13.

FIGURA 13: Países que mais realizaram *tweets*

FONTE: Elaborado pelo autor

Este gráfico demonstra claramente que a maior número de *tweets* foram publicados do Brasil e apenas uma pequena quantia deles foram realizados nos Estados Unidos, Argentina, Portugal e Venezuela. É importante notar que nem todos os *tweets* gerados possuem um país de origem semelhante a situação anterior, onde a API do *Twitter* os classificam como *undefined*, porém não é apresentado no gráfico da Figura 13.

Utilizando uma biblioteca para expressões regulares, é possível procurar por *tweets* de palavras específicas, ou *hashtags* mesmo o usuário digitando com letras maiúsculas ou minúsculas.

O Código 7, apresenta uma função que procura determinadas palavras dentro do *DataFrame*. Estas palavras então preenchem uma coluna com os *tweets* relacionados com a palavra buscada. As palavras buscadas são referentes às *hashtags* que mais foram publicadas nesta data.

```

1 import re
2
3
4 def word_in_text(word, text):
5     word = word.lower()
6     text = text.lower()
7     match = re.search(word, text)
8     if match:
9         return True
10    return False
11
12 tweets['NaoVaiTerGolpe'] = tweets['text'].apply(lambda tweet: ↵
    word_in_text('NaoVaiTerGolpe', tweet))
13 tweets['TchauQuerida'] = tweets['text'].apply(lambda tweet: word_in_text(↵
    'TchauQuerida', tweet))
14 tweets['ForaDilma'] = tweets['text'].apply(lambda tweet: word_in_text('↵
    ForaDilma', tweet))
15 tweets['BrasilContraOGolpe'] = tweets['text'].apply(lambda tweet: ↵
    word_in_text('BrasilContraOGolpe', tweet))
16 tweets['ForaCunha'] = tweets['text'].apply(lambda tweet: word_in_text('↵
    ForaCunha', tweet))
17
18 # print tweets['FicaQuerida'].value_counts()[True]
19 # print tweets['NaoVaiTerGolpe'].value_counts()[True]
20 # print tweets['ForaPT'].value_counts()[True]
21
22 hashtags = ['ForaDilma', 'NaoVaiTerGolpe', 'TchauQuerida', '↵
    BrasilContraOGolpe', 'ForaCunha']
23 tweets_by_hashtags = [tweets['ForaDilma'].value_counts()[True],
24                        tweets['NaoVaiTerGolpe'].value_counts()[True],
25                        tweets['TchauQuerida'].value_counts()[True],
26                        tweets['BrasilContraOGolpe'].value_counts()[True],
27                        tweets['ForaCunha'].value_counts()[True]]
28
29 plt.subplots(figsize=(9,9))
30 colors = ['gold', 'yellowgreen', 'lightcoral', 'lightskyblue', 'peachpuff↵
    ']
31 explode = (0.03, 0.03, 0.03, 0.05, 0.03)
32 plt.pie(tweets_by_hashtags, explode=explode, labels=hashtags, colors=↵
    colors,
33         autopct='%1.1f%%', shadow=True, startangle=140)
34 plt.rcParams['font.size'] = 12

```


```

35 plt.legend(tweets_by_hashtags, loc=(1,.6))
36 plt.axis('equal')
37 plt.show()

```

CÓDIGO 7: Buscar *hashtags* mais publicadas

As *hashtags* são contabilizadas e apresentadas através do gráfico de setores da Figura 14. Onde é possível verificar a porcentagem referente aos *tweets* realizados com a *hashtag* #ImpeachmentDay.

FIGURA 14: *Hashtags* com o maior número de *tweets*

FONTE: Elaborado pelo autor

Através da Figura 14, as *hashtags* #ForaDilma e #TchauQuerida somam um total de 60,7% que apoiam o processo de Impeachment da presidente da República, diferente dos 34,3% dos *tweets* que é o somatório de #BrasilContraOGolpe e #Nao-VaiTerGolpe.

Dando continuidade ao uso da biblioteca para trabalhar com expressões regulares, o Código 8 permite encontrar *links* que são publicados pelos usuários através de seus *tweets*. Estes *links* podem ser filtrados de acordo com a *hashtag* utilizada.

```

1 def extract_link(text):
2     regex = r'https?://[^\s<>"]+|www\.[^\s<>"]+'
3     match = re.search(regex, text)
4     if match:
5         return match.group()
6     return ''
7
8 tweets['link'] = tweets['text'].apply(lambda tweet: extract_link(tweet))
9
10 tweets_relevant = tweets[tweets['ImpeachmentDay'] == True]
11 tweets_relevant_with_link = tweets_relevant[tweets_relevant['link'] != '']
12
13 print tweets_relevant_with_link[tweets_relevant_with_link['TchauQuerida'] == True]['link']
14 print tweets_relevant_with_link[tweets_relevant_with_link['ForaDilma'] == True]['link']
15 print tweets_relevant_with_link[tweets_relevant_with_link['ForaCunha'] == True]['link']
16 print tweets_relevant_with_link[tweets_relevant_with_link['NaoVaiTerGolpe'] == True]['link']

```

CÓDIGO 8: Extração de *links* provenientes de *tweets*

O resultado da execução do Código 8, é uma lista de milhares de *links* e o número em ordem do *tweet* encontrado no *DataFrame*. A Figura 15 apresenta um pedaço desta lista para exemplificação.

Semelhante ao Código 7, é possível aplicar o filtro das *hashtags* para encontrar nomes com maior popularidade através do Código 9.

```

1 tweets['moro'] = tweets['text'].apply(lambda tweet: word_in_text('moro', tweet))
2 tweets['cunha'] = tweets['text'].apply(lambda tweet: word_in_text('cunha', tweet))
3 tweets['bolsonaro'] = tweets['text'].apply(lambda tweet: word_in_text('bolsonaro', tweet))
4 tweets['lula'] = tweets['text'].apply(lambda tweet: word_in_text('lula', tweet))
5 tweets['temer'] = tweets['text'].apply(lambda tweet: word_in_text('temer', tweet))
6 tweets['feliciano'] = tweets['text'].apply(lambda tweet: word_in_text('feliciano', tweet))
7
8 hashtags = ['Sergio Moro'.decode('utf-8'), 'Eduardo Cunha', 'Jair Bolsonaro', 'Lula', 'Michel Temer', 'Marcos Feliciano']
9 tweets_by_hashtags = [tweets['moro'].value_counts()[True],
10 tweets['cunha'].value_counts()[True],

```

8871	https://t.co/rtOavI9uQP
8906	https://t.co/VswJPAt5u1
9619	https://t.co/IiXU4ICRrH
9685	https://t.co/tlt3wTQ969
9904	https://t.co/y2MILsrv6I
45728	https://t.co/crggdefh02
53250	https://t.co/Y50qDJkPXP
62948	https://t.co/5mqsWBDIHh
63335	https://t.co/Kck2W7uc9B
64182	https://t.co/Odd6HZPlJU
67891	https://t.co/yJ1BGtHGhd
68558	https://t.co/rTvrUyAHA9
83968	https://t.co/XinE7SVm1F
90123	https://t.co/gAraHA4Fdt
90129	https://t.co/XinE7SVm1F
91107	https://t.co/XinE7SVm1F
91160	https://t.co/XinE7SVm1F
101356	https://t.co/6hOBQnYHhW

FIGURA 15: Exemplo de *links* extraídos de *tweets*

FONTE: Elaborado pelo autor

```

11 tweets['bolsonaro'].value_counts()[True],
12 tweets['lula'].value_counts()[True],
13 tweets['feliciano'].value_counts()[True],
14 tweets['temer'].value_counts()[True]]
15
16 plt.subplots(figsize=(8,8))
17 colors = ['gold', 'yellowgreen', 'lightcoral', 'lightskyblue', 'peachpuff',
18           'mediumturquoise']
19 explode = (0.03, 0.03, 0.03, 0.05, 0.03, 0.03)
20 plt.pie(tweets_by_hashtags, explode=explode, labels=hashtags, colors=
21         colors,
22         autopct='%1.1f%%', shadow=True, startangle=90)
23 plt.rcParams['font.size'] = 12
24 plt.legend(tweets_by_hashtags, loc='best')
25 plt.axis('equal')
26 plt.show()

```

CÓDIGO 9: Filtro para coletar nomes com mais *tweets*

Como resultado o Código 9, constrói um gráfico de setores, nesse é possível verificar a porcentagem de *tweets* para nomes específicos através da Figura 16, porém não é possível, ainda, predizer se os argumentos a respeito destas pessoas são positivos ou negativos.




FIGURA 16: Gráfico de setores para figuras importantes

FONTE: Elaborado pelo autor

O gráfico de setores representado pela Figura 16, demonstra que o nome mais mencionado foi de Eduardo Cunha e com apenas 2618 *tweets* o nome de Michel Temer foi publicado. Até mesmo as menções ao ex-presidente Luiz Inácio "Lula" da Silva recebeu apenas 18,8% do total dos nomes filtrados.

6 CONCLUSÕES E SUGESTÕES PARA FUTUROS TRABALHOS

6.1 CONCLUSÕES

A utilização das bibliotecas que Python oferece para a mineração de dados permite que o desenvolvimento das soluções se tornem mais rápidos e efetivos. Assim como a utilização da API do *Twitter* para a obtenção dos dados e as etapas do processo de *data mining*.

Escrevendo...

6.2 SUGESTÕES PARA FUTUROS TRABALHOS

REFERÊNCIAS

- BRACHMAN, R. J. et al. The process of knowledge discovery in databases. 1996. Acesso em 23 de outubro de 2015. Disponível em: <<https://www.aaai.org/Papers/Workshops/1994/WS-94-03/WS94-03-001.pdf>>.
- BRAIN, S. **Twitter Statistics**. 2016. Acesso em 20 de abril de 2016. Disponível em: <<http://www.statisticbrain.com/twitter-statistics/>>.
- CODD, E. F. A relational model of data for large shared data banks. 1969. Acesso em 04 de outubro de 2015. Disponível em: <<https://www.seas.upenn.edu/~zives/03f/cis550/codd.pdf>>.
- CONWAY, D.; WHITE, J. M. **Machine Learning For Hackers**. [S.l.]: O'Reilly Media, 2012. ISBN 978-1-449-30371-6.
- FAYYAD, U. et al. From data mining to knowledge discovery in databases. 1996–a. Acesso em 23 de outubro de 2015. Disponível em: <<http://www.csd.uwo.ca/faculty/ling/cs435/fayyad.pdf>>.
- FAYYAD, U. et al. Advances in knowledge discovery in data mining. 1996–b.
- FIELDING, R. T. Architectural styles and the design of network-based software architectures. 2000.
- HAN, J. et al. **Data Mining: Concepts and Techniques**. [S.l.]: Elsevier, 2012.
- HARRINGTON, P. **Machine Learning in Action**. [S.l.]: Manning Publications, 2012. ISBN 9781617290183.
- HUBERMAN, B. A.; ROMERO, D. M.; WU, F. Social networks that matter: Twitter under the microscope. **Available at SSRN 1313405**, 2008.
- JANSSENS, J. **Data Science at the Command Line**. [S.l.]: O'Reilly Media, 2014. ISBN 978-1-4919-4779-1.
- KALDERO, N. **Why is Python a language of choice for data scientists?** 2015. Acesso em 27 de outubro de 2015. Disponível em: <<http://qr.ae/RkleiB>>.
- KWAK, H. et al. What is twitter, a social network or a news media? In: ACM. **Proceedings of the 19th international conference on World wide web**. [S.l.], 2010. p. 591–600.
- LEMOES, E. P. **Análise de crédito bancário com o uso de data mining: redes neurais e árvores de decisão**. Tese (Doutorado) — Universidade Federal do Paraná, 2003.
- MCKINNEY, W. **Python for Data Analysis**. [S.l.]: O'Reilly, 2013.
- NAVEGA, S. Princípios essenciais do data mining. 2002.
- PIPINO, L.; KOPCSO, D. Data mining, dirty data, and costs. In: **IQ**. [S.l.: s.n.], 2004. p. 164–169.

PYTHON. **Python 3.4.3 Documentation**. 2015. Acesso em 21 de novembro de 2015. Disponível em: <<https://docs.python.org/3.4/>>.

RUSSELL, M. A. **Mining the Social Web**. [S.l.]: O'Reilly Media, 2013. ISBN 978-1-449-36761-9.

SFERRA, H. H.; CORREA, A. M. C. J. Conceitos e aplicações de data mining. 2003.

SILVA, M. P. da; BOSCARIOLI, C.; PERES, S. M. Análise de logs da web por meio de técnicas de data mining. 2003.

STEINER, M. T. A. et al. Data-mining como suporte à tomada de decisões-uma aplicação no diagnóstico médico. **XXXVI SIMPÓSIO BRASILEIRO DE PESQUISA OPERACIONAL, "O IMPACTO DA PESQUISA OPERACIONAL NAS NOVAS TENDÊNCIAS MULTIDISCIPLINARES**, v. 23, p. 96–107, 2004.

TWEEPY, D. **Biblioteca Tweepy - 3.5.0**. 2009. Acesso em 03 de abril de 2016. Disponível em: <<http://tweepy.readthedocs.org/en/v3.5.0/index.html>>.

TWITTER. **Tweet Example**. 2016. Acesso em 24 de abril de 2016. Disponível em: <<https://twitter.com/unixstickers/status/724338974043574272>>.

TWITTER. **Twitter Documentation**. 2016. Acesso em 21 de abril de 2016. Disponível em: <<https://dev.twitter.com/overview/documentation>>.

WEBBER, J.; PARASTATIDIS, S.; ROBINSON, I. **REST in Practice - Hypermedia and Systems Architecture**. [S.l.]: O'Reilly, 2010.

WIENER, E. Matplotlib tools. 2014. Acesso em 27 de novembro de 2015. Disponível em: <<https://wiki.ucar.edu/display/ral/Matplotlib+Tools>>.